

BAB III

LANDASAN TEORI

3.1 Tinjauan Pustaka

Sebagai landasan yang komprehensif, bagian ini menguraikan perkembangan studi terdahulu yang sejalan dengan fokus penelitian penulis. Kajian literatur ini bertujuan untuk menjadi tolok ukur perbandingan serta memvalidasi kebaruan dari sistem yang dikembangkan. Berikut disajikan ringkasan dari empat literatur utama yang menjadi rujukan:

Tabel 3.1. Hasil Penelitian Terdahulu

No.	Peneliti (Tahun)	Judul Penelitian	Metode	Hasil/Kesimpulan
1.	Rostami et al. (2022) [6]	<i>A Novel Time-Aware Food Recommender-System...</i>	<i>Deep Learning & Graph Clustering</i>	Kelebihan: Sistem ini menggunakan weighted linear combination yang interpretable dan komputasional ringan; dapat dijalankan tanpa GPU; bobot dapat di-tune via env var tanpa retraining; multi-pilar (cosine + freshness + quality) bukan hanya satu sisi. Kekurangan: Komputasi mahal karena bergantung pada deep learning; bersifat black-box

Tabel 3.1. Hasil Penelitian Terdahulu (lanjutan)

No.	Peneliti (Tahun)	Judul Penelitian	Metode	Hasil/Kesimpulan
				sehingga sulit dijelaskan; membutuhkan dataset berskala besar untuk pelatihan; tidak mendukung penyajian real-time pada latensi rendah.
2.	SAI Org (2022) [7]	<i>Exponential Decay Function-Based Time-Aware Recommender System...</i>	<i>Exponential Decay Function</i>	Kelebihan: Sistem ini menambahkan komponen <i>Cosine Similarity</i> untuk personalisasi minat dan <i>Quality Score</i> untuk penilaian kualitas konten; tidak hanya bergantung pada dimensi waktu; menyediakan jalur fallback Trending untuk kondisi <i>cold-start</i> Kekurangan: Penelitian hanya mempertimbangkan dimensi waktu; tidak memiliki komponen personalisasi minat (no content similarity); tidak mengagregasi metrik kualitas seperti rating, like, dan engagement.
3.	Liu et al. (2022) [8]	<i>TD-DNN: A Time Decay-Based Deep Neural Network...</i>	<i>Time Decay & Deep Neural Network</i>	Kelebihan: Sistem ini deterministik dan reproducible (untuk input yang sama menghasilkan output identik); interpretable (kontribusi setiap pilar dapat dianalisis terpisah); latensi sub-detik tanpa inferensi neural network; mudah di-tune manual. Kekurangan: Mahal secara komputasi karena inferensi DNN; output bersifat stokastik (sulit di-

Tabel 3.1. Hasil Penelitian Terdahulu (lanjutan)

No.	Peneliti (Tahun)	Judul Penelitian	Metode	Hasil/Kesimpulan
				reproduce); interpretability rendah karena model black-box; sulit di-tune bobot komponen secara manual tanpa retraining.
4.	Pilgram et al. (2025) [9]	<i>A consensus privacy metrics...</i>	<i>Time-Based Decay Function</i>	Kelebihan: Sistem ini secara spesifik dirancang untuk content recommendation; lengkap dengan arsitektur backend operasional, REST API, caching, dan paginasi kursor; divalidasi melalui pengujian akurasi (NDCG/Precision/Recall) yang relevan untuk domain feed konten. Kekurangan: Konteks aplikasi adalah privacy metrics, bukan content recommendation; tidak menangani metrik kualitas konten; tidak divalidasi pada domain feed atau ranking konten kreatif.

Berdasarkan keseluruhan analisis komparatif, terdapat empat pembeda utama yang menegaskan posisi dan kontribusi orisinal penelitian ini jika dibandingkan dengan jajaran penelitian terdahulu. Pembeda pertama terletak pada penerapan pendekatan hibrida deterministik dengan kombinasi linier terbobot (*weighted linear combination*) sebagaimana dikategorikan oleh literatur taksonomi rekomendasi hibrida [3].

Berbeda dengan mayoritas penelitian sebelumnya yang cenderung mengadopsi model generatif atau prediktif berbasis *deep learning* yang kompleks, penelitian ini secara sengaja memilih skema kombinasi linear karena karakteristiknya yang jauh lebih ringan, bersifat deterministik, serta memiliki tingkat interpretabilitas yang tinggi, sehingga sangat ideal untuk memenuhi tuntutan latensi rendah pada arsitektur backend lingkungan produksi. Selanjutnya, pembeda kedua dicerminkan melalui integrasi dimensi waktu sebagai pilar independen yang berdiri sendiri, bukan sekadar diposisikan sebagai variabel pelengkap untuk penanganan pergeseran konsep (*concept-drift handling*). Melalui formulasi komponen *Freshness Score* (Persamaan 3.2), sistem secara proaktif memberikan penalti usia secara eksponensial pada konten-konten lama guna menjamin ruang visibilitas yang adil bagi konten baru yang berkualitas, di mana fitur krusial ini jarang ditemukan pada model konvensional yang umumnya hanya memanfaatkan fungsi time decay untuk mendeteksi dinamika perubahan minat pengguna.

Pembeda ketiga yang tidak kalah penting adalah mekanisme kuantifikasi metrik interaksi yang disintesis melalui komponen *Quality Score*, alih-alih hanya bergantung pada masukan umpan balik eksplisit berupa *rating* konvensional. Penelitian ini memfokuskan ekstraksi nilai dari umpan balik implisit (*implicit feedback*) seperti *like_count*, *used_count*, dan *watch_count* yang kemudian diproses menggunakan teknik normalisasi logaritmik [12], sebuah pendekatan komputasi modern yang terbukti lebih akurat dalam merepresentasikan lanskap interaksi dinamis pada platform penyedia konten masa kini. Akhirnya, pembeda keempat ditunjukkan dari cara penelitian ini memposisikan sistem rekomendasi

bukan sekadar sebagai alat teknis untuk maksimalisasi akurasi prediksi semata, melainkan sebagai sebuah ekosistem penemuan konten yang seimbang dan sehat. Dengan menekankan titik kesetimbangan (*trade-off*) yang presisi antara dimensi personalisasi dan kebaruan, arsitektur yang dibangun mampu menyajikan halaman feed yang tidak hanya relevan secara personal bagi setiap individu, tetapi juga secara aktif menjaga keberagaman (*diversity*) konten guna menanggulangi jebakan isolasi informasi (*filter bubble*) yang kerap menjadi kelemahan mendasar pada sistem yang hanya berorientasi pada nilai akurasi mutlak.

3.2 Dasar Teori

3.2.1 Platform Media Sosial dan Konten Buatan Pengguna

Platform media sosial didefinisikan sebagai sekelompok aplikasi dan ekosistem digital berbasis internet yang dibangun di atas fondasi ideologis serta teknologis Web 2.0, yang secara fundamental memungkinkan penciptaan, kurasi, dan pertukaran Konten Buatan Pengguna atau *User-Generated Content* (UGC) [24]. Dalam perkembangannya, platform media sosial tidak lagi sekadar menjadi ruang komunikasi statis, melainkan bertransformasi menjadi komunitas konten interaktif yang digerakkan sepenuhnya oleh partisipasi aktif penggunanya. Studi literatur terkini menegaskan bahwa keberadaan UGC telah menjadi pilar paling krusial yang menentukan tingkat retensi, popularitas platform, serta kekuatan hubungan interaksi antar pengguna di dalam ruang digital [25].

Dari perspektif teori platform, nilai dan keberlanjutan sebuah platform media sosial tumbuh melalui efek jaringan (*network effects*). Konsep ini menjelaskan bahwa semakin banyak kreator yang memproduksi konten dan semakin banyak pengguna yang mengonsumsinya, maka akan semakin tinggi pula utilitas dan nilai ekonomi platform tersebut secara keseluruhan [26]. Namun, konsekuensi langsung dari model dua sisi (*two-sided model*) ini adalah munculnya fenomena kelebihan muatan informasi (*information overload*) ketika volume produksi UGC tumbuh secara eksponensial. Dalam kondisi lonjakan data yang masif tersebut, platform diwajibkan untuk menyediakan mekanisme kurasi informasi yang berjalan secara otomatis untuk menjembatani sisi produksi dan sisi konsumsi konten agar pengguna tidak kesulitan menemukan informasi yang relevan [26].

Platform Remakes yang menjadi objek penelitian ini merupakan instansiasi nyata dari platform media sosial berbasis UGC. Di dalam ekosistem ini, pihak kreator memproduksi template perintah kecerdasan buatan (*generative AI prompts*), sementara pengguna akhir mengonsumsinya, memodifikasinya, dan menggandakannya menjadi karya visual yang baru. Karakteristik operasional inilah yang menjadikan teori platform media sosial dan UGC sangat relevan sebagai landasan teoretis penelitian. Hal ini sekaligus menegaskan urgensi mengapa platform Remakes mutlak membutuhkan implementasi sistem rekomendasi yang cerdas sebagai instrumen kurasi untuk mengelola lalu lintas distribusi konten kreatif tersebut.

3.2.2 Strategi Konten dan Distribusi Konten Digital

Strategi konten didefinisikan sebagai praktik sistematis yang memandu perencanaan, penciptaan, penyampaian, dan tata kelola konten yang relevan bagi pengguna di ruang digital [27]. Dalam ekosistem platform penyedia konten berskala besar, algoritma rekomendasi tidak berdiri sendiri sebagai entitas komputasi semata, melainkan menjadi komponen integral dari strategi tata kelola tersebut. Algoritma berfungsi sebagai distributor otomatis yang menentukan konten mana yang dipresentasikan kepada audiens, kapan waktu penayangannya, dan dengan urutan prioritas seperti apa [28]. Keberhasilan distribusi konten digital karenanya tidak hanya ditentukan oleh kualitas produksi dari sisi kreator, tetapi juga oleh strategi penyebaran sistem yang memastikan sebuah konten menjangkau audiens yang relevan secara efektif.

Salah satu prinsip kunci dalam strategi distribusi konten modern adalah menjaga titik keseimbangan antara relevansi minat dan kebaruan informasi [28]. Strategi distribusi yang hanya menonjolkan konten-konten populer dengan tingkat interaksi historis tertinggi akan memicu konsentrasi perhatian audiens yang tidak proporsional. Fenomena ini berisiko menciptakan sirkulasi konten yang stagnan, di mana dominasi karya lama (efek *rich-get-richer*) secara perlahan mematikan ruang eksposur bagi konten-konten terbaru yang belum sempat mendapatkan atensi.

Prinsip pemerataan distribusi inilah yang secara langsung diadaptasi oleh penelitian ini. Arsitektur *Time-Aware Hybrid Ranking System* yang dibangun dirancang sebagai realisasi teknis dari strategi tata kelola konten yang sehat dan adil. Dengan memadukan pilar relevansi minat (*Content Similarity*), kualitas

interaksi (*Engagement Metrics*), serta penalti keluruhan usia konten (*Time Decay*), sistem memastikan bahwa karya terbaru dari kreator di platform Remakes tetap memperoleh peluang tayang di halaman utama sebelum bersaing berdasarkan metrik kualitas interaksinya.

3.2.3 Pembagian Format Konten Digital

Konten digital dapat diklasifikasikan secara mendasar berdasarkan format representasinya, yang secara umum mencakup teks, gambar, audio, video, dan media interaktif. Pembagian format ini memiliki implikasi langsung terhadap pola konsumsi audiens, proses produksi, serta cara sistem mengevaluasi kualitas keterlibatan (*engagement*) [28]. Literatur mengenai interaksi media membuktikan bahwa setiap format memiliki kapasitas yang berbeda dalam memicu perhatian pengguna; format visual dan multimedia (seperti gambar dan video) tergolong sebagai *rich media* karena mampu menyampaikan isyarat informasi secara instan, sehingga secara empiris terbukti menghasilkan tingkat keterlibatan dan interaksi yang jauh lebih tinggi dibandingkan format teks murni [29].

Pada platform Remakes, konten difokuskan pada penyediaan format visual, yakni *template perintah kecerdasan buatan (prompt)* yang menghasilkan luaran berupa gambar dan desain generatif. Di samping dimensi format media tersebut, setiap objek konten di dalam platform diikat oleh satu atau lebih label klasifikasi kategori (misalnya: Teknologi, Edukasi, Bisnis, atau Finansial). Pembagian format berbasis kategori terstruktur inilah yang secara teknis dialihfungsikan sebagai dimensi pemetaan selera pengguna. Representasi kategori ini selanjutnya dikonversi menjadi masukan ruang vektor dalam algoritma *Cosine Similarity*,

menjadikan teori pembagian format dan klasifikasi konten sebagai fondasi konseptual mutlak bagi arsitektur perhitungan relevansi di dalam sistem.

3.2.4 Sistem Rekomendasi

Sistem rekomendasi merupakan perangkat lunak dan teknik algoritmik yang dirancang untuk memberikan saran (*suggestions*) berupa item atau konten yang diprediksi paling relevan dan berguna bagi pengguna tertentu [12]. Di era digital dengan pertumbuhan data yang eksponensial, sistem ini menjadi solusi fundamental untuk mengatasi masalah kelebihan muatan informasi (*information overload*), sehingga pengguna tidak perlu menelusuri seluruh katalog konten secara manual [11]. Lebih jauh lagi, implementasi sistem rekomendasi telah terbukti menjadi instrumen pendukung keputusan yang sangat esensial di berbagai ekosistem, termasuk pada ranah akademik institusional. Hal ini sejalan dengan penelitian Asfi & Fitriarningsih (2020) yang membuktikan bahwa algoritma sistem rekomendasi (seperti *classifier*) dapat difungsikan untuk menyelesaikan permasalahan subjektivitas, contohnya dalam merekomendasikan dosen pembimbing skripsi secara objektif dan akurat [10]. Di ranah kecerdasan buatan (AI) lainnya, efektivitas algoritma komputasi juga dibuktikan oleh penelitian Jacob, Subagio, dan Nursetyo (2025) yang menggunakan pendekatan RuleBased Expert System sebagai sistem pakar penunjang keputusan yang presisi dan berjalan secara otomatis [19]. Secara tradisional, paradigma sistem rekomendasi diklasifikasikan ke dalam dua pendekatan utama, yaitu [11]:

1. *Content-Base Filtering* (CBF)

Pendekatan ini merekomendasikan item berdasarkan kemiripan atribut atau metadata dari item tersebut dengan profil preferensi pengguna di masa lalu. Dalam konteks platform konten, algoritma ini akan merekomendasikan sebuah konten jika kategori atau fitur konten tersebut memiliki kemiripan (*similarity*) yang tinggi dengan konten-konten yang sebelumnya sering diinteraksikan oleh pengguna.

2. *Collaborative Filtering* (CF)

Pendekatan ini tidak bergantung pada atribut konten, melainkan pada pola historis interaksi (seperti pemberian peringkat atau klik) dari sekumpulan pengguna. CF merekomendasikan item yang disukai oleh pengguna lain yang memiliki profil selera atau perilaku yang serupa dengan pengguna target.

Meskipun kedua metode tersebut populer, masing-masing memiliki keterbatasan yang signifikan. Pendekatan CF sangat rentan terhadap masalah *cold-start* (ketidakmampuan memberikan rekomendasi ketika sistem memiliki pengguna atau item baru yang belum memiliki riwayat interaksi) serta masalah matriks data yang renggang (*data sparsity*) [3]. Di sisi lain, CBF sering kali terjebak pada masalah spesialisasi berlebihan (*overspecialization*), di mana pengguna hanya akan direkomendasikan jenis konten yang sama secara berulang-ulang tanpa adanya variasi penemuan baru [13].

Untuk mengatasi keterbatasan dari pendekatan-pendekatan tunggal tersebut, dikembangkanlah konsep Hybrid Recommender System (Sistem Rekomendasi Hibrida). Sistem hibrida bekerja dengan menggabungkan dua atau lebih teknik rekomendasi untuk memaksimalkan kelebihan dan meminimalkan kelemahan masing-masing metode. Pada penelitian ini, konsep hibrida diimplementasikan dengan memadukan pencocokan preferensi minat pengguna berbasis kategori

konten (*Content Similarity*), yang selanjutnya diperkaya dan dibobotkan bersama metrik interaksi kualitas (*Engagement Metrics*) serta fitur kontekstual berupa dinamika waktu rilis konten (*Time-Aware Ranking*). Penggabungan ini bertujuan untuk menghasilkan peringkat *feed* yang sangat terpersonalisasi namun tetap menjaga kebaruan (*freshness*) informasi bagi pengguna.

Untuk mengatasi masalah *cold-start* pada pengguna baru, sistem yang diusulkan menerapkan strategi penanganan bertingkat (*multi-tier fallback strategy*) yang dirancang sesuai konteks ketersediaan data setiap pengguna. Pendekatan ini sejalan dengan rekomendasi pada literatur sistem rekomendasi hibrida modern [3], yang menyatakan bahwa *fallback* bertingkat merupakan teknik efektif untuk menjaga ketersediaan rekomendasi pada kondisi data minim. Tiga tingkatan strategi yang diterapkan adalah sebagai berikut:

1. *Cold-Start* Pengguna Anonim

Apabila pengguna mengakses sistem tanpa autentikasi, profil minat berbentuk vektor preferensi belum tersedia. Sistem secara otomatis melayani *feed* melalui algoritma trending global, yaitu pengurutan konten berdasarkan kombinasi metrik popularitas tanpa melibatkan komponen *Cosine Similarity*. Strategi ini memastikan pengguna baru tetap memperoleh konten populer yang relevan secara umum [9].

2. *Cold-Start* Pengguna Anonim

Untuk pengguna yang telah mendaftar tetapi belum memiliki rekam jejak interaksi, vektor preferensi U bernilai nol, sehingga *Cosine Similarity* (Persamaan 3.1) menghasilkan nilai nol. Sistem mendeteksi kondisi ini dan secara otomatis

mengaktifkan jalur *fallback* ke kandidat trending yang telah dipra-komputasi pada cache.

3. *Cold-Start* dengan Preferensi Eksplisit dari *Onboarding*

Sistem menangkap preferensi eksplisit saat *onboarding* (registrasi awal). Preferensi ini disimpan dan ditambahkan sebagai skor dasar (*base score*) ke vektor preferensi pengguna *U* untuk memberikan dorongan awal pada perhitungan *Cosine Similarity*, sehingga personalisasi dapat aktif segera setelah registrasi. Pendekatan ini terbukti efektif mempersingkat masa *cold-start* [3].

3.2.5 *Arsitektur Sistem Rekomendasi Dua Tahap (Two-Stage Recommender System)*

Dalam implementasi sistem rekomendasi berskala besar, mengevaluasi dan menghitung skor kecocokan (seperti algoritma *Cosine Similarity* dan *Time Decay*) pada seluruh populasi data konten untuk setiap permintaan pengguna akan memakan biaya komputasi yang sangat besar dan mengakibatkan latensi yang tidak dapat diterima [12]. Untuk mengatasi tantangan skalabilitas tersebut, arsitektur sistem rekomendasi modern umumnya memecah proses pemfilteran ke dalam desain pipa data (*pipeline*) dua tahap:

Pembangkitan Kandidat (*Candidate Generation*) dan Perankingan (*Ranking/Scoring*) [12], [11].

1. Tahap Pembangkitan Kandidat (*Candidate Generation*)

Fase pertama ini berfungsi sebagai corong penyaring awal (*funnel*) yang bertujuan untuk mereduksi ruang lingkup pencarian secara masif. Sistem menyeleksi jutaan entri dalam basis data menjadi himpunan kandidat berukuran

kecil (ratusan item) secara cepat dan komputasional murah [11]. Dalam konteks arsitektur hibrida, pengumpulan kandidat sering kali dilakukan dengan mengambil item dari berbagai *pool* atau strategi pencarian yang berjalan secara paralel untuk mencegah isolasi preferensi pengguna atau *filter bubble* [3]. Pada sistem yang diusulkan, kandidat diekstraksi dari tiga himpunan utama:

- a). Kandidat berdasarkan metrik interaksi global tertinggi (*Trending-based*).
- b). Kandidat berdasarkan ketertarikan kategori historis pengguna (*Interest-based*).
- c). Kandidat berdasarkan unggahan paling mutakhir (*Freshness-based*).

Seluruh kandidat dari berbagai sumber ini kemudian digabungkan (*merged*) dan dieliminasi duplikasinya sebelum masuk ke fase berikutnya [3].

2. Tahap Perankingan (*Ranking/Scoring*)

Fase kedua berfokus pada presisi dan penilaian mendalam terhadap himpunan kandidat terbatas yang telah lolos dari fase pertama [12]. Karena jumlah data yang diproses sudah jauh lebih kecil, sistem dapat menerapkan kalkulasi matematis komposit yang lebih berat untuk menentukan skor relevansi absolut dari setiap konten. Pada tahap inilah pilar algoritma hibrida utama dioperasikan secara bersamaan [13].

Setiap kandidat dinilai berdasarkan tingkat kemiripan vektor kategorinya (*Content Similarity*), kualitas interaksi historisnya (*Engagement Metrics*), serta penalti peluruhan waktu (*Time-Awareness*). Konten yang memiliki skor gabungan hibrida tertinggi akan diurutkan secara menurun (*descending*) untuk dipresentasikan sebagai daftar rekomendasi akhir atau *For You Page* (FYP) kepada pengguna [11], [13]. Pendekatan penilaian dan perankingan berbasis multi-atribut

ini sejalan dengan penelitian Andika, Kusnadi, dan Sokibi (2020), yang membuktikan bahwa metode komputasi pembobotan multi-kriteria sangat efektif untuk menghasilkan keputusan rekomendasi yang objektif dan presisi [22].

3.2.6 *Cosine Similarity*

Cosine Similarity adalah salah satu metrik pengukuran jarak (*distance metric*) yang paling masif dieksploitasi dalam sistem pemfilteran berbasis konten untuk mengevaluasi derajat kesamaan antara dua profil atau entitas [11]. Metrik ini tidak berfokus pada pengukuran selisih besaran ukuran (*magnitude*) antara dua profil, melainkan mengukur nilai kosinus sudut yang terbentuk di antara dua vektor tak nol di dalam sebuah ruang multidimensi (*multidimensional vector space*) [14].

Dalam konteks arsitektur sistem rekomendasi yang dikembangkan pada penelitian ini, algoritma *Cosine Similarity* secara spesifik diimplementasikan untuk mengkalkulasi tingkat relevansi antara vektor preferensi kategori milik pengguna (U) terhadap vektor atribut kategori yang merepresentasikan sebuah objek konten (C) [11]. Secara matematis, formulasi dari *Cosine Similarity* didefinisikan melalui persamaan berikut [14]:

$$sim(U, C) = \cos(\theta) = \frac{U \cdot C}{||U|| \cdot ||C||} = \frac{\sum_{i=1}^n U_i \cdot C_i}{\sqrt{\sum_{i=1}^n U_i^2} \cdot \sqrt{\sum_{i=1}^n C_i^2}} \quad (\text{Persamaan 3.1})$$

Keterangan persamaan di atas adalah sebagai berikut:

1. U_i merepresentasikan nilai bobot ketertarikan pengguna terhadap kategori ke- i (didapatkan dari riwayat interaksi pengguna).
2. C_i merepresentasikan keberadaan (*boolean*) atau bobot kategori ke- i yang melekat pada objek konten kandidat.

3. n mewakili total dimensi dari ruang vektor, yang ekuivalen dengan jumlah keseluruhan variasi kategori yang terdaftar di dalam sistem basis data.

Hasil dari perhitungan ruang vektor ini selalu menghasilkan metrik berskala dengan rentang nilai antara 0 hingga 1. Jika skor yang diproduksi mendekati nilai 1, kondisi tersebut mengindikasikan bahwa sudut antar vektor sangatlah sempit ($\theta \approx 0^\circ$), yang secara semantik berarti konten kandidat memiliki tingkat kemiripan atau kecocokan selera yang sangat identik dengan riwayat pengguna [4]. Sebaliknya, apabila skor yang dihasilkan mendekati atau sama dengan 0, kedua vektor diasumsikan saling tegak lurus (*orthogonal*), yang menegaskan ketiadaan irisan korelasi antara profil minat pengguna dengan kategori konten yang tengah dievaluasi [14]. Dalam kalkulasi perankingan hibrida yang diusulkan, metrik *Cosine Similarity* ini diposisikan sebagai pilar *Interest-Based* utama pembentuk skor akhir konten.

3.2.7 Time-Aware Ranking dan Exponential Time Decay

Sistem rekomendasi tradisional umumnya berasumsi bahwa preferensi pengguna dan relevansi sebuah item bersifat statis dari waktu ke waktu. Namun, pada platform penyedia konten yang dinamis, asumsi ini tidak lagi relevan [15]. Preferensi pengguna dapat bergeser, dan kebaruan (*novelty*) dari sebuah konten memiliki masa kedaluwarsa. Oleh karena itu, diperkenalkanlah paradigma *Time-Aware Recommender System* (TARS), yaitu sistem yang secara eksplisit memodelkan waktu sebagai dimensi kontekstual tambahan dalam proses perankingan [15].

Salah satu teknik paling efektif dan komputasional ringan untuk mengimplementasikan TARS adalah melalui penggunaan fungsi peluruhan waktu

atau *Time Decay Function* [16]. Secara khusus, *Exponential Time Decay* memberikan penalti secara mulus pada skor relevansi sebuah item berdasarkan usianya [16]. Pendekatan ini memastikan bahwa *item* yang baru dipublikasikan memiliki keunggulan visibilitas sementara, yang secara perlahan akan menyusut seiring berjalannya waktu, sehingga mencegah dominasi konten lama di halaman rekomendasi.

Sesuai dengan implementasi arsitektur sistem pada penelitian ini, skor kebaruan konten (*Freshness Score*) dihitung menggunakan persamaan peluruhan eksponensial berikut [16]:

$$S_{fresh}(C) = e^{-\frac{\Delta t}{\lambda}} \quad (\text{Persamaan 3.2.4})$$

Keterangan dari persamaan di atas adalah:

1. $S_{fresh}(C)$ adalah skor kebaruan akhir yang akan berkisar antara 0 hingga 1.
2. e adalah konstanta bilangan Euler (≈ 2.71828).
3. Δt adalah usia konten atau selisih antara waktu saat ini dengan waktu konten dibuat, yang direpresentasikan dalam satuan jam (*hours*).
4. λ adalah konstanta waktu paruh (*half-life parameter*) yang mengontrol seberapa curam kurva peluruhan terjadi. Pada penelitian ini, nilai λ ditetapkan sebesar 72.0 (mewakili 72 jam atau 3 hari), yang berarti konten akan kehilangan sebagian besar bobot kebaruannya secara signifikan setelah melewati siklus 3 hari.

Melalui integrasi fungsi peluruhan ini, sistem *hybrid* tidak hanya melayani kecocokan minat (*interest-based*), tetapi juga secara proaktif mendistribusikan eksposur (*exposure*) yang adil bagi konten-konten yang baru diunggah [15], [16].

3.2.8 Engagement Metrics dan Normalisasi Data

Kualitas intrinsik dari sebuah konten harus dievaluasi untuk memastikan bahwa sistem merekomendasikan item yang berharga. Evaluasi ini dilakukan dengan mengekstraksi *Engagement Metrics* (metrik keterlibatan), yaitu kumpulan sinyal interaksi historis pengguna terhadap konten tersebut [11]. Sinyal interaksi ini dapat berupa umpan balik eksplisit (*explicit feedback*) seperti rata-rata penilaian, maupun umpan balik implisit (*implicit feedback*) seperti jumlah klik, jumlah tayangan, penggunaan templat, dan jumlah suka [11].

Dalam membangun formula sistem hibrida, penggabungan langsung nilai *Engagement Metrics* (yang batas atasnya tidak terhingga) dengan skor probabilitas seperti seperti *Cosine Similarity* (yang bernilai 0 hingga 1) akan menyebabkan ketidakseimbangan model (*model bias*) [14]. Variabel dengan rentang nilai absolut yang jauh lebih besar akan mendominasi dan mengabaikan variabel lainnya [14].

Untuk menanggulangi ketimpangan ini, diperlukan teknik pra-pemrosesan data berupa Normalisasi (*Data Normalization*). Pada penelitian ini, teknik normalisasi penskalaan maksimum absolut (*Max-Absolute Scaling* atau turunan dari *Min-Max Normalization*) diterapkan untuk memampatkan nilai interaksi mentah ke dalam skala rasio homogen antara 0 hingga 1 [14]. Persamaan normalisasi tersebut didefinisikan sebagai:

$$X_{norm} = \frac{X}{X_{max}} \quad (\text{Persamaan 3.2})$$

Di mana X adalah nilai interaksi konten saat ini (misalnya jumlah suka dari sebuah postingan), dan X_{max} adalah nilai interaksi tertinggi dari seluruh himpunan kandidat yang sedang diproses pada ruang pencarian yang sama [14]. Hasil dari normalisasi metrik ini kemudian dikombinasikan (menjadi parameter *Quality*

Score) bersama skor kemiripan dan skor kebaruan untuk menghasilkan nilai *ranking* hibrida yang terkalibrasi secara seimbang.

3.2.9 Hybrid Final Score

Ketiga pilar penilaian kemiripan minat (*Cosine Similarity*), kebaruan konten (*Exponential Time Decay*), dan kualitas interaksi (*Quality Score*) terkalkulasi pada rentang ternormalisasi $[0, 1]$, langkah terakhir pada fase Ranking adalah menggabungkan ketiga skor tersebut menjadi satu metrik komposit tunggal yang menjadi dasar pengurutan akhir konten. Penggabungan ini menggunakan paradigma weighted linear combination sebagaimana dikategorikan dalam taksonomi sistem rekomendasi hibrida sebagai weighted hybrid recommender. Output dari beberapa teknik dihitung bersamaan dan dijumlahkan dengan bobot yang telah ditentukan.

Persamaan formal skor hibrida final pada penelitian ini didefinisikan sebagai berikut:

$$Score_{final}(c) = \omega_1 \cdot Cosine(u, c) + \omega_2 \cdot S_{fresh}(c) + \omega_3 \cdot Quality(c) \text{ (Persamaan 3.3)}$$

Keterangan persamaan:

1. $Score_{final}(c)$ adalah skor akhir konten kandidat c untuk pengguna u , pada rentang $[0, 1]$.
2. $Cosine(u, c)$ adalah skor kemiripan minat.
3. $S_{fresh}(c)$ adalah skor kebaruan konten (c).
4. $Quality(c)$ adalah skor kualitas konten (c).

5. ω_1, ω_2 , dan ω_3 adalah konstanta pembobotan.

Konstanta pembobotan tunduk pada kendala normalisasi:

$$\omega_1 + \omega_2 + \omega_3 = 1, \omega_i \in [0,1] \quad \forall_i \in \{1, 2, 3\}$$

Pada penelitian ini, ditetapkan nilai konstanta pembobotan sebagai berikut:

$$\omega_1 = 0,55, \omega_2 = 0,25 \quad \omega_3 = 0,20$$

Pemilihan kombinasi nilai ini didasarkan pada pertimbangan berikut:

1. Dominansi Pilar Minat (Cosine Similarity): Bobot tertinggi 0,55 dialokasikan untuk memastikan bahwa konten selaras dengan riwayat ketertarikan kategoris pengguna.
2. Kontribusi Moderat Pilar Kebaruan (Freshness): Bobot 0,25 memberikan visibilitas adil bagi konten baru tanpa mengorbankan relevansi minat, mencegah dominasi konten lama.
3. Kontribusi Penyaring Kualitas (Quality Score): Bobot 0,20 diposisikan sebagai filter terhadap konten berkualitas rendah, berfungsi sebagai pembanding antar konten dengan relevansi serupa.

Sifat matematis dari skor akhir ini bersifat monotonically non-decreasing dan memiliki kompleksitas komputasi rendah $O(n)$, memungkinkan respons real-time yang deterministik dan mudah di-tuning. Pada tahap akhir, sistem menerapkan pengurutan komposit sebagai berikut:

$$ORDER BY Score_{final}(c) DESC \rightarrow t_c DESC \rightarrow ID_{(c)} DESC \text{ (Persamaan 3.4)}$$

3.2.10 Hybrid Final Score

Formula skor hibrida telah didefinisikan, langkah berikutnya adalah melakukan validasi empiris terhadap kualitas rekomendasi. Penelitian ini

mengadopsi tiga metrik komplementer: Precision@K, Recall@K, dan Normalized Discounted Cumulative Gain (NDCG@K)

1. Precision@K dan Recall@K

Precision@K mengukur proporsi konten relevan dalam himpunan K rekomendasi teratas:

$$Precision@K = \frac{|\{c \in R_k : rel(u, c) > 0\}|}{K} \quad (Persamaan 3.5)$$

Recall@K mengukur proporsi konten relevan yang berhasil ditemukan sistem dari seluruh konten relevan pada katalog:

$$Recall@K = \frac{|\{c \in R_k : rel(u, c) > 0\}|}{|\{c \in D : rel(u, c) > 0\}|} \quad (Persamaan 3.6)$$

Kedua metrik ini saling melengkapi, namun tidak mempertimbangkan urutan konten dalam top-K.

2. Normalized Discounted Cumulative Gain (NDCG@K)

Untuk menjawab keterbatasan Precision dan Recall, NDCG@K memberikan bobot penalti pada konten relevan yang menempati posisi rendah. Komputasi NDCG@K terdiri dari tiga tahap:

a). DCG@K: Menghitung perolehan relevansi terdiskon:

$$DCG@K = \sum_{i=1}^K \frac{2^{rel_i} - 1}{\log_2(i + 1)} \quad (Persamaan 3.7)$$

b). IDCG@K: Menghitung perolehan relevansi terdiskon:

$$IDCG@K = \sum_{i=1}^K \frac{2^{rel_i^*} - 1}{\log_2(i + 1)} \quad (Persamaan 3.8)$$

c). Normalisasi: Skor akhir diperoleh dengan membagi DCG dengan IDCG:

$$NDCG@K = \frac{DCG@K}{IDCG@K} \quad (Persamaan 3.9)$$

Penelitian ini menggunakan skala relevansi bertingkat (*graded relevance*) dengan tingkat $\{0, 1, 2, 3\}$ untuk representasi kecocokan yang lebih realistis dan kompatibel dengan NDCG [N+3].

3.2.11 Pengujian Hipotesis Statistik

Untuk memastikan bahwa perbedaan metrik yang dihasilkan bukan merupakan fluktuasi acak, dilakukan pengujian hipotesis statistik [N+4]. Pada penelitian ini, hipotesis nol (H_0) dan hipotesis alternatif (H_1) dirumuskan sebagai berikut:

$$H_0: \mu_{\text{PROP}} = \mu_B$$

$$H_1: \mu_{\text{PROP}} > \mu_B$$

Di mana μ_{PROP} dan μ_B adalah rata-rata nilai NDCG@K populasi untuk sistem *proposed* dan *baseline*. Karena setiap pengguna sintetis dievaluasi pada kedua sistem, digunakan pengujian *paired t-test* [13]. Statistik uji t dihitung dengan persamaan:

$$t = \frac{\bar{d}}{s_d/\sqrt{N}} \quad (\text{Persamaan 3.10})$$

Kriteria keputusan ditentukan dengan membandingkan nilai p -value terhadap tingkat signifikansi $\alpha = 0,05$ [13]:

$$\text{Keputusan} = \begin{cases} \text{Tolak } H_0 & \text{apabila } p\text{-value} < 0,05 \\ \text{Gagal Tolak } H_0 & \text{apabila } p\text{-value} \geq 0,05 \end{cases}$$

Ketentuan ini menggaransi keseimbangan sensitivitas dalam mendeteksi perbedaan secara ilmiah, berdasarkan asumsi data berpasangan dan distribusi yang memenuhi Teorema Limit Pusat [N+4]

3.2.12 Pengujian Black-Box

Pengujian *black-box* adalah metode pengujian perangkat lunak yang mengevaluasi kesesuaian keluaran (*output*) sistem terhadap masukan (*input*) yang diberikan, tanpa memeriksa struktur internal atau kode sumber program. Fokus pengujian diletakkan pada pemenuhan kebutuhan fungsional (*functional requirement*), di mana sistem dianggap sebagai "kotak hitam" yang hanya diamati perilaku operasionalnya. Dalam literatur rekayasa perangkat lunak modern, metode ini sangat lazim diimplementasikan untuk menguji fungsionalitas dan ketahanan Application Programming Interface (*RESTful Web API*) secara berkesinambungan [30]. Pada penelitian ini, pengujian *black-box* dipilih karena pemisahan antara system under test (layanan *backend* algoritma Go) dan instrumen pengujian dapat menjamin objektivitas hasil tanpa bias terhadap detail implementasi kode. Pengujian direalisasikan dengan menyusun serangkaian kasus uji (*test case*) yang memetakan skenario kondisi masukan menuju respons daftar rekomendasi keluaran yang diharapkan.

3.2.13 Studi Ablation dan Analisis Sensitivitas Parameter

Studi ablation adalah metode evaluasi analitis yang dilakukan dengan menonaktifkan atau menghilangkan satu komponen sistem secara sistematis guna mengukur kontribusi independen komponen tersebut terhadap performa model secara keseluruhan. Metode ini, berdampingan dengan analisis sensitivitas (*sensitivity analysis*) yang berfungsi mengukur seberapa besar perubahan keluaran model akibat variasi rentang nilai parameter masukannya, telah menjadi standar validasi baku dalam literatur pengembangan sistem rekomendasi modern [31]. Pada penelitian ini, analisis sensitivitas dieksekusi melalui pencarian sistematis pada

ruang parameter (*grid search*) untuk membuktikan bahwa pemilihan konstanta pembobotan ($\omega_1, \omega_2, \omega_3$) bersifat optimal dan dilandasi oleh bukti empiris. Di sisi lain, studi ablation digunakan untuk memvalidasi secara ilmiah bahwa masing-masing pilar komputasi (kemiripan minat, peluruhan usia, dan kualitas interaksi) memberikan nilai tambah yang signifikan terhadap presisi algoritma.

3.2.14 Pengujian Kinerja Sistem (Performance / Load Testing)

Pengujian kinerja merupakan pendekatan eksperimental untuk mengevaluasi tingkat responsivitas dan stabilitas aplikasi komputasi di bawah kondisi beban kerja tertentu. Terdapat dua metrik fundamental dalam evaluasi sistem terdistribusi: waktu respons (*response time* atau latensi) yang merepresentasikan durasi penyelesaian satu permintaan siklus penuh, serta throughput yang mengukur kapasitas penyelesaian permintaan per satuan waktu (RPS) [32]. Untuk sistem yang dirancang melayani konkurensi tinggi, pengujian beban (*load testing*) mutlak dilakukan dengan menyimulasikan akses dari berbagai pengguna virtual secara bersamaan. Dalam penelitian ini, pengujian kinerja bertujuan membuktikan klaim bahwa algoritma perankingan yang dirancang sanggup menyajikan daftar rekomendasi secara *real-time* (dengan batas toleransi latensi $p_{95} < 500$ ms). Pengukuran difokuskan pada nilai persentil distribusi latensi (p_{50}, p_{95}, p_{99}) guna memberikan gambaran pengalaman pengguna yang lebih akurat pada titik beban operasional puncak (*tail latency*).