

BAB IV

ANALISIS DAN PERANCANGAN

4.1 Analisis Masalah

4.1.1 Tantangan yang Dihadapi

Studi kasus pada penelitian ini berpusat pada perancangan arsitektur fundamental untuk platform Remakes yang baru saja dikembangkan. Sebagai platform penyedia layanan kecerdasan buatan (*generative AI*) yang diproyeksikan akan mengakomodasi basis kreator dan pengguna dalam skala besar, pihak klien mengantisipasi munculnya tantangan teknis berupa kelebihan muatan informasi di masa mendatang. Seiring dengan peluncuran platform dan eskalasi akuisisi pengguna, ratusan hingga ribuan templat kecerdasan buatan baru diperkirakan akan membanjiri basis data sistem setiap harinya. Tanpa adanya mesin penyaring konten yang cerdas sejak awal, pengguna kelak akan dihadapkan pada lautan konten yang acak, yang pada akhirnya dapat menghambat pertumbuhan awal tingkat retensi dan kepuasan pengguna.

Sebagai langkah preventif dari proyeksi permasalahan tersebut, klien membutuhkan perancangan sebuah sistem algoritma rekomendasi halaman utama yang dituntut untuk menyelesaikan tiga kebutuhan esensial sejak hari pertama platform beroperasi. Kebutuhan pertama adalah personalisasi yang adil, di mana sistem harus mampu memetakan probabilitas ketertarikan pengguna berdasarkan riwayat interaksinya, namun tetap dibekali mekanisme mitigasi (*fallback*) untuk

menyajikan konten bagi lonjakan pengguna baru yang belum memiliki rekam jejak (*cold-start*). Kebutuhan kedua adalah visibilitas kreator baru, di mana algoritma tidak boleh hanya mengandalkan metrik popularitas yang berisiko memicu monopoli konten (*rich-get-richer*), melainkan harus secara proaktif memberikan ruang eksposur bagi karya-karya yang baru saja dirilis ke dalam sistem. Kebutuhan ketiga adalah penyaringan kualitas, di mana platform membutuhkan penyaring otomatis yang mampu membedakan konten berkualitas tinggi dari konten bernilai rendah agar ekosistem kreator tetap sehat seiring dengan lonjakan data di masa depan.

4.1.2 Deskripsi Platform Remakes

Studi kasus yang menjadi objek penelitian dan implementasi arsitektur ini adalah platform Remakes. Remakes merupakan platform inovatif berbasis layanan kecerdasan buatan (*generative AI*) yang dirancang khusus untuk memfasilitasi kreator dan pengguna akhir dalam membuat, mendistribusikan, serta mengonsumsi konten kreatif digital berupa gambar dan video melalui pemanfaatan *prompt template*. Platform ini mempertemukan dua kepentingan utama: kreator yang memproduksi templat perintah kecerdasan buatan yang optimal, dan pengguna umum yang ingin menghasilkan karya visual berkualitas tinggi secara instan tanpa harus menguasai keahlian *prompt engineering* yang rumit.

Di dalam ekosistem operasional Remakes, pengguna dibagi menjadi dua peran utama dengan batasan wewenang yang diatur secara ketat oleh sistem:

1. Pengguna Akhir

Merupakan aktor yang berinteraksi dengan platform melalui aplikasi *mobile*. Aktivitas utama mereka meliputi eksplorasi halaman *feed* untuk menemukan konten rekomendasi yang dipersonalisasi, pemanfaatan *template AI* untuk menghasilkan karya baru, pemberian umpan balik berupa *like*, *rating*, dan *share*, serta pengelolaan transaksi keuangan berupa pengisian ulang (*top-up*) saldo token sebagai instrumen pembayaran biaya komputasi *generative AI*.

2. Moderator (*Mod*)

Merupakan aktor administratif yang mengelola jalannya platform melalui antarmuka web khusus panel kontrol. Tanggung jawab moderator meliputi pengelolaan katalog paket *top-up*, pengiriman notifikasi *push* massal, pelaksanaan moderasi terhadap konten atau pengguna yang melanggar ketentuan layanan, serta validasi dan pemrosesan transaksi penarikan dana dari para kreator.

4.1.3 Tantangan yang Dihadapi

Sebagai platform konten modern yang mengalami pertumbuhan data secara eksponensial, Remakes dihadapkan pada sejumlah tantangan teknis struktural yang apabila tidak ditangani dengan baik akan menurunkan retensi pengguna dan kualitas ekosistem platform. Tantangan utama tersebut diuraikan sebagai berikut:

1. Personalisasi yang Adil (*Fair Personalization*)

Sistem harus mampu menyajikan konten yang relevan dengan minat unik setiap individu. Masalah krusial muncul ketika pengguna baru mendaftar dan belum memiliki rekam jejak interaksi histori sama sekali (*cold-start*), di mana algoritma konvensional akan gagal memproses rekomendasi.

2. Visibilitas Konten Baru (*Freshness Visibility*)

Algoritma *feed* tradisional cenderung terjebak pada bias popularitas, di mana konten lama yang sudah viral akan terus mendominasi halaman utama (*rich-get-richer*). Sistem dituntut untuk memberikan kesempatan eksposur yang adil bagi konten-konten baru yang berkualitas agar ekosistem kreator tetap hidup.

3. Latensi Rendah (*Low Latency*)

Komputasi algoritma perankingan hibrida yang melibatkan pencarian ruang vektor dan operasi temporal yang kompleks harus diselesaikan dalam waktu sub-detik (kurang dari 500 ms) demi menjaga kelancaran gulir *infinite scroll* pengguna.

4. Skalabilitas *High-Throughput*

Infrastruktur harus tangguh dalam menopang ratusan hingga ribuan permintaan pemuatan *feed* secara bersamaan tanpa mengalami lonjakan kegagalan server atau penurunan drastis pada waktu respons.

5. Penghancuran *Filter Bubble*

Algoritma tidak boleh terlalu spesifik merekomendasikan satu jenis konten secara berulang-ulang yang dapat mengisolasi cakupan informasi pengguna, melainkan harus menyisipkan elemen keberagaman (*diversity*) secara terkontrol.

4.1.4 Lingkup Sistem yang Dikembangkan

Mengatasi tantangan teknis di atas, penelitian ini membatasi ruang lingkup pengembangan secara ketat pada ranah rekayasa layanan *backend* (*server-side service*) yang menjadi mesin utama platform Remakes. Kontribusi utama dari sistem yang dikembangkan meliputi rancangan arsitektur rekomendasi dua-tahap (*Candidate Generation* dan *Ranking*), mesin kalkulasi nilai hibrida komposit, manajemen memori penyimpanan sementara (*read-through caching*) berbasis Redis, serta mekanisme paginasi data menggunakan kursor (*cursor-based*

pagination). Seluruh antarmuka pengguna, baik aplikasi *mobile* maupun panel web admin, diposisikan berada di luar lingkup penelitian ini dan diasumsikan berinteraksi dengan sistem menggunakan protokol komunikasi REST API formal.

4.1.5 Identifikasi Entitas Data dan Komponen Sistem

Dalam merealisasikan logika perankingan untuk mengatasi tantangan tersebut, sistem diidentifikasi secara fungsional berdasarkan entitas data masukan dan komponen pemrosesan intinya. Komponen-komponen penyokong ini disajikan secara terstruktur pada Tabel 4.1.

Tabel 4.1 Definisi Entitas Data dan Komponen Sistem

Kategori	Nama Komponen	Deskripsi Fungsional
Data Masukan	Data Konten	Entitas yang menyimpan informasi detail mengenai sebuah karya atau templat, yang mencakup parameter waktu publikasi, nilai rata-rata ulasan (<i>rating</i>), dan jumlah interaksi agregat (<i>like, view, used</i>).
	Data Pengguna	Entitas yang menyimpan identitas unik, status otentikasi, dan saldo token dari setiap pengguna terdaftar di platform.
	Data Kategori	Label klasifikasi yang melekat pada setiap objek konten (misalnya: Teknologi, Edukasi, Bisnis) untuk keperluan pemetaan selera.
	Profil Minat Pengguna	Sebuah matriks yang merekam akumulasi nilai ketertarikan seorang pengguna terhadap kategori tertentu. Nilai ini terus diperbarui seiring dengan frekuensi interaksi pengguna.
Komponen Pemrosesan	Orkestrator Perankingan	Mesin perangkat lunak utama yang bertugas mengatur alur kerja: mulai dari memuat data konten mentah, mengirimkannya ke fungsi penilaian, hingga mengurutkan hasil akhirnya.
	Fungsi Penilaian	Komponen komputasi matematis yang bertugas mengeksekusi tiga formula untuk memberikan nilai pada setiap konten: Skor Kemiripan Minat, Skor Kebaruan, dan Skor Kualitas.

4.2 Spesifikasi Algoritma Time-Aware Hybrid Ranking

Sub-bab ini menyajikan spesifikasi formal dari Algoritma *Time-Aware Hybrid Ranking* yang menjadi inti kontribusi penelitian. Spesifikasi ini disusun untuk menjabarkan batasan masukan dan keluaran sistem, struktur data logis penyokong komputasi, representasi *pseudocode* dan diagram alir tingkat rendah, serta evaluasi matematis terhadap kompleksitas waktu dan ruang dari algoritma yang diusulkan.

4.2.1 Input dan Output Algoritma

Secara formal, algoritma perankingan hibrida ini didefinisikan sebagai sebuah fungsi pemetaan $\mathcal{F}$ yang mengonversi identitas pengguna dan parameter konfigurasi lingkungan menjadi sebuah daftar rekomendasi konten yang telah terurut dan terpaginasi secara deterministik. Rincian spesifikasi masukan (*input*) dan keluaran (*output*) dari fungsi algoritma tersebut didefinisikan pada Tabel 4.2.

Tabel 4.2 Profil minat pengguna pengujian

Kategori	Parameter	Tipe Data	Deskripsi Fungsional
Input Wajib	user_id	UUID	Pengenal unik pengguna terotentikasi sebagai acuan penarikan vektor minat.
	K	Integer	Batas jumlah pemotongan luaran konten (<i>default</i> : 10 entri).
	cursor	String	Parameter opsional berbasis <i>Base64</i> sebagai penanda <i>offset</i> paginasi berlanjut.
Input Parameter	w_1	Float $\in [0,1]$	Konstanta bobot kombinasi linier untuk pilar <i>Cosine Similarity</i> .
	w_2	Float $\in [0,1]$	Konstanta bobot kombinasi linier untuk pilar <i>Freshness</i> .
	w_3	Float $\in [0,1]$	Konstanta bobot kombinasi linier untuk pilar <i>Quality</i> .
	λ	Float	Konstanta waktu paruh (dalam jam) untuk peluruhan eksponensial usia konten.


Tabel 4.2 Profil minat pengguna pengujian (Lanjutan)

Kategori	Parameter	Tipe Data	Deskripsi Fungsional
Output Utama	top_K_contents	List of Content	Daftar K konten yang diurutkan secara menurun berdasarkan skor komposit hibrida.

Berdasarkan Tabel 4.2 agar fungsi $\mathcal{F}$ beroperasi tanpa memicu anomali perhitungan (*computational exception*), algoritma menerapkan prasyarat (*preconditions*) berupa kendala normalisasi bobot mutlak ($w_1 + w_2 + w_3 = 1$) serta nilai $\lambda > 0$ dan $K \geq 1$. Apabila eksekusi selesai, algoritma menjamin pemenuhan pascasyarat (*postconditions*) di mana daftar keluaran memiliki panjang maksimal K , bebas dari duplikasi data, serta memiliki keterurutan yang deterministik apabila diuji dengan dataset dan parameter masukan yang identik.

4.2.2 Algorithmic Flowchart

Visualisasi kronologis dapat dipetakan dalam bentuk diagram alir algoritma (*algorithmic flowchart*). Berbeda dengan *Activity Diagram* yang memodelkan interaksi lintas-aktor, alir algoritma ini berfokus pada hierarki pemecahan masalah mesin secara deterministik, terutama terkait percabangan kondisi ketersediaan data pengguna.



Gambar 4.2 Flowchart Algoritma

Berdasarkan diagram alir tersebut, sistem memberlakukan fungsi pendeteksi ketidaktersediaan rekam jejak pengguna (*cold-start observer*) sebagai gerbang logika paling krusial di awal alur komputasi. Apabila panjang norma *Euclid* dari

vektor ketertarikan bernilai nol ($||U|| = 0$), mesin pemrosesan membatalkan serangkaian operasi aritmetika kompleks dari *Cosine Similarity* dan penalti keluruhan waktu. Sebaliknya, alur ini akan dideretkan langsung untuk mengadopsi tumpukan data dari kolom *Trending* global sebagai mekanisme penyelamat pelayanan ketersediaan halaman *feed*.

Pada jalur aliran normal, algoritma memasuki fase paralelisasi pengumpulan data, di mana agregasi tiga kolom terpisah (*Trending*, *Freshness*, *Interest*) disatukan secara himpunan matematis dan dieliminasi nilai gandanya. Mesin kemudian memutar siklus perulangan (*looping*) untuk menghitung tiga pilar skor berdasarkan matriks pembobotan, dan ditutup dengan pemotongan deret larik data sesuai batasan rentang kursor sebelum akhirnya melakukan hidrasi informasi secara spesifik hanya pada K -entri teratas.

4.2.3 Analisis Kompleksitas Waktu dan Ruang

Untuk menjamin bahwa arsitektur yang dirancang layak dieksekusi dalam skenario *real-time* berskala produksi, dilakukan evaluasi matematis secara asimtotik terhadap kompleksitas kinerja algoritmik atau notasi *Big-O*. Penilaian meliputi evaluasi waktu eksekusi (*Time Complexity*) serta alokasi penggunaan memori kerja (*Space Complexity*). Pemetaan kompleksitas dirangkum pada Tabel 4.3.

Tabel 4.3 Profil minat pengguna pengujian

Fase Operasional	Formula Kompleksitas Waktu	Formula Kompleksitas Ruang	Parameter Pertumbuhan
<i>Candidate Retrieval</i> (Pemuatan Cache)	$O(1)$ amortized	$O(n)$	n = Total akumulasi kandidat dari berbagai kolam.
Deduplikasi Kandidat (<i>Hash Set Merge</i>)	$O(n)$	$O(n)$	n = Kandidat mentah disisipkan pada struktur data <i>set</i> .
Iterasi Kalkulasi Skor Komposit Hibrida	$O(n \cdot d)$	$O(n)$	d = Total variasi dimensi kategori minat (konstan/skala kecil).
<i>Composite Sorting</i> (Urutan Menurun)	$O(n \log n)$	$O(\log n)$	Fase paling membebani berbasis perbandingan <i>Timsort/Quicksort</i> .
Pemotongan <i>Array</i> (Paginasi <i>Slice</i>)	$O(K)$	$O(K)$	K = Panjang halaman maksimum luaran API.
Hidrasi Objek ke Basis Data Utama	$O(K)$	$O(K)$	<i>Overhead</i> relasional jaringan ke MySQL dibatasi hanya K baris.
Batas Atas Total Kompleksitas	$O(n \log n)$	$O(n)$	Didominasi murni oleh fase pengurutan memori.

Berdasarkan tabel 4.3 pembuktian asimtotik di atas, pertumbuhan operasi terberat algoritma ini berada pada $O(n \log n)$ yang merupakan kompleksitas ruang waktu sangat efisien untuk proses perankingan dua-tahap (*Two-Stage Ranking*). Mengingat himpunan kandidat awal n dipaksa reduksi maksimal sebesar ≈ 900 objek setelah deduplikasi, jumlah iterasi komputasi yang wajib dijalankan oleh unit pemrosesan server sangatlah minim (≈ 8.800 operasi dasar per permintaan basis).

Sementara itu, kompleksitas memori $O(n)$ menyatakan bahwa alokasi *overhead* sementara yang ditaruh ke memori RAM server (*heap memory*) hanya sebatas ratusan struktur data kecil berkisar 180 KB per satu panggilan fungsi

algoritma. Kombinasi kompleksitas efisien ini menjadi bukti teknis yang sangat solid mengapa sistem perankingan ini diproyeksikan mampu menghasilkan target latensi median (p95) di bawah 500 ms secara stabil meskipun dilanda lalu lintas transaksi yang padat secara serentak.

4.3 Contoh Perhitungan Manual Algoritma Platform Remakes

Untuk memvalidasi ketepatan matematis model perankingan hibrida sebelum ditransformasikan ke dalam baris kode program, bagian ini menyajikan simulasi perhitungan manual *step-by-step* berdasarkan skenario eksperimental terukur.

1. Skenario Simulasi

Simulasi melibatkan seorang pengguna terotentikasi yang merepresentasikan arketipe Tech Enthusiast. Matriks ketertarikan historis pengguna diekstraksi dari tabel *user_category_stats* ke dalam lima dimensi ruang vektor kategori fungsional: *Technology*, *Education*, *Design*, *Business*, *Finance*. Profil nilai preferensi pengguna didefinisikan pada Tabel 4.4.

Tabel 4.4 Profil minat pengguna pengujian

Kategori	Skor Minat (u_i)
<i>Technology</i>	80
<i>Education</i>	30
<i>Design</i>	10
<i>Business</i>	5

Tabel 4.4 Profil minat pengguna pengujian (Lanjutan)

Kategori	Skor Minat (u_i)
<i>Finance</i>	2

Sistem mengidentifikasi lima objek konten kreatif yang lolos dari fase pembangkitan kandidat awal dengan karakteristik atribut mentah sebagaimana tertera pada Tabel 4.5.

Tabel 4.5 Atribut Objek Konten Kandidat

ID	Nama konten	Kategori	Usia konten (Δt , jam)	Rating (r_c)	Jumlah suka (L_c)
C1	Template AI Coding Assistant	<i>Technology, Education</i>	6	4,5	250
C2	Template Desain Logo Modern	<i>Design</i>	12	4,0	100
C3	<i>Pitch Deck Template untuk Tech Startup</i>	<i>Business, Technology</i>	36	4,2	180
C4	Tutorial Manajemen Bisnis untuk UMKM	<i>Business, Education</i>	60	4,7	400
C5	Template Laporan Keuangan Tahunan	<i>Finance</i>	24	4,3	200

2. Pemetaan dan Kalkulasi Norma Vektor Pengguna

Representasi spasial vektor profil pengguna U disusun berdasarkan urutan dimensi koordinat [*Technology; Education; Design; Business; Finance*]:

$$U = [80; 30; 10; 5; 2]$$

Kalkulasi panjang norma Euclidean L_2norm dari vector U dilakukan menggunakan rumus sebagai berikut:

$$\|\vec{U}\| = \sqrt{\sum_{i=1}^d u_i^2}$$

$$\begin{aligned}\|\vec{U}\| &= \sqrt{80^2 + 30^2 + 10^2 + 5^2 + 2^2} = \sqrt{6400 + 900 + 100 + 25 + 4} \\ &= \sqrt{7429} \approx 86,19\end{aligned}$$

Batas atas jumlah suka maksimum pada ruang pencarian kandidat diidentifikasi sebagai pembagi skala logaritmik:

$$L_{\max} = \max(250, 100, 180, 400, 200) = 400$$

3. Komputasi Pilar Kedekatan Ruang Minat (*Cosine Similarity*)

Derajat kemiripan dihitung dengan membagi produk titik perkalian dua vektor terhadap perkalian panjang norma masing-masing entitas (Persamaan 3.1). Atribut kategori konten bernilai 1 jika kategori melekat pada konten, dan 0 jika tidak.

Rumus:

$$\text{Cosine}(\vec{U}, \vec{C}_c) = \frac{\vec{U} \cdot \vec{C}_c}{\|\vec{U}\| \times \|\vec{C}_c\|}$$

a). Konten C1 (*Technology, Education*)

$$C_1 = [1; 1; 0; 0; 0] \rightarrow \|C_1\| = \sqrt{1^2 + 1^2} = \sqrt{2} \approx 1,414$$

$$U \cdot C_1 = (80 \times 1) + (30 \times 1) = 110$$

$$\text{Cosine}(u, C_1) = \frac{110}{86,19 \times 1,414} = \frac{110}{121,87} \approx 0,9026$$

b). Konten C2 (*Design*)

$$C_2 = [0; 0; 1; 0; 0] \rightarrow \|C_2\| = 1$$

$$U \cdot C_2 = (10 \times 1) = 10 \rightarrow \text{Cosine}(u, C_2) = \frac{10}{86,19 \times 1} \approx 0,1160$$

c). Konten C3 (*Business, Technology*)

$$C_3 = [1; 0; 0; 1; 0] \rightarrow \|C_3\| = \sqrt{2} \approx 1,414$$

$$U \cdot C_3 = (80 \times 1) + (5 \times 1) = 85 \rightarrow \text{Cosine}(u, C_3) = \frac{85}{121,87} \approx 0,6975$$

d). Konten C4 (*Business, Education*)

$$C_4 = [0; 1; 0; 1; 0] \rightarrow \|C_4\| = \sqrt{2} \approx 1,414$$

$$U \cdot C_4 = (30 \times 1) + (5 \times 1) = 35 \rightarrow \text{Cosine}(u, C_4) = \frac{35}{121,87} \approx 0,2872$$

e). Konten C5 (*Finance*)

$$C_5 = [0; 0; 0; 0; 1] \rightarrow \|C_5\| = 1$$

$$U \cdot C_5 = (2 \times 1) = 2 \rightarrow \text{Cosine}(u, C_5) = \frac{2}{86,19 \times 1} \approx 0,0232$$

4. Komputasi Pilar Kebaruan Konten (*Exponential time decay*)

Perhitungan nilai penalti temporal usia konten memanfaatkan fungsi peluruhan eksponensial (*Exponential Time Decay*) dengan rumus umum:

$$S_{\text{fresh}}(c) = e^{-\frac{\Delta t}{\lambda}}$$

Dimana Δt merepresentasikan selisih waktu pembuatan konten dalam satuan jam dan λ adalah konstanta waktu paruh peluruhan sebesar 72 jam.

a). C1 ($\Delta t = 6 \text{ jam}$): $S_{\text{fresh}}(C_1) = e^{-6/72} = e^{-0,0833} \approx 0,9200$

b). C2 ($\Delta t = 12 \text{ jam}$): $S_{\text{fresh}}(C_2) = e^{-12/72} = e^{-0,1667} \approx 0,8465$

c). C3 ($\Delta t = 36 \text{ jam}$): $S_{\text{fresh}}(C_3) = e^{-36/72} = e^{-0,5000} \approx 0,6065$

d). C4 ($\Delta t = 60 \text{ jam}$): $S_{\text{fresh}}(C_4) = e^{-60/72} = e^{-0,8333} \approx 0,4346$

e). C5 ($\Delta t = 24 \text{ jam}$): $S_{\text{fresh}}(C_5) = e^{-24/72} = e^{-0,3333} \approx 0,7165$

5. Komputasi Pilar Kualitas Interaksi (*Quality Score*)

Perhitungan menggabungkan nilai rating ternormalisasi skala 5 dan penskalaan maksimum absolut logaritmik jumlah suka, dengan rumus umum:

$$\text{Quality}(c) = w_r \cdot \left(\frac{r_c}{5}\right) + w_e \cdot \left(\frac{\ln(1 + L_c)}{\ln(1 + L_{\max})}\right)$$

Dimana pembobotan $w_r = 0,7$ dan $w_e = 0,3$. Konstanta pembagi logaritmik bernilai $\ln(1 + 400) = \ln(401) \approx 5,9940$.

$$\text{a). Quality}(C_1) = 0,7 \times \frac{4,5}{5} + 0,3 \times \frac{\ln(1+250)}{5,9940}$$

$$= 0,6300 + 0,3 \times \frac{5,5255}{5,9940}$$

$$= 0,6300 + 0,2765 = 0,9065$$

$$\text{b). C2: Quality}(C_2) = 0,7 \times \frac{4,0}{5} + 0,3 \times \frac{\ln(1+100)}{5,9940} = 0,5600 + 0,3 \times \frac{4,6151}{5,9940} =$$

$$0,5600 + 0,2310 = 0,7910$$

$$\text{c). C3: Quality}(C_3) = 0,7 \times \frac{4,2}{5} + 0,3 \times \frac{\ln(1+180)}{5,9940} = 0,5880 + 0,3 \times \frac{5,1985}{5,9940} =$$

$$0,5880 + 0,2602 = 0,8482$$

$$\text{d). C4: Quality}(C_4) = 0,7 \times \frac{4,7}{5} + 0,3 \times \frac{\ln(1+400)}{5,9940} = 0,6580 + 0,3 \times \frac{5,9940}{5,9940} =$$

$$0,6580 + 0,3000 = 0,9580$$

$$\text{e). C5: Quality}(C_5) = 0,7 \times \frac{4,3}{5} + 0,3 \times \frac{\ln(1+200)}{5,9940} = 0,6020 + 0,3 \times \frac{5,3033}{5,9940} =$$

$$0,6020 + 0,2654 = 0,8674$$

6. Sintesis Komposit Skor Hibrida *Final*

Nilai penentuan posisi akhir dirumuskan mengacu pada model kombinasi linear terbobot dengan menggabungkan ketiga pilar nilai decimal yang homogen melalui rumus:

$$\text{Score}_{\text{final}}(c) = w_1 \cdot \text{Cosine}(U, C_c) + w_2 \cdot S_{\text{fresh}}(c) + w_3 \cdot \text{Quality}(c)$$

Dimana parameter bobot pengaruh yang ditetapkan adalah $w_1 = 0,55$, $w_2 = 0,25$ (Kebaruan Waktu), dan $w_3 = 0,20$ (Mutu Kualitas).

- a). $\text{Score}(C_1) = (0,55 \times 0,9026) + (0,25 \times 0,9200) + (0,20 \times 0,9065)$
 $= 0,4964 + 0,2300 + 0,1813 = \mathbf{0,9077}$
- b). $\text{Score}(C_2) = (0,55 \times 0,1160) + (0,25 \times 0,8465) + (0,20 \times 0,7910) =$
 $0,0638 + 0,2116 + 0,1582 = \mathbf{0,4336}$
- c). $\text{Score}(C_3) = (0,55 \times 0,6975) + (0,25 \times 0,6065) + (0,20 \times 0,8482) =$
 $0,3836 + 0,1516 + 0,1696 = \mathbf{0,7048}$
- d). $\text{Score}(C_4) = (0,55 \times 0,2872) + (0,25 \times 0,4346) + (0,20 \times 0,9580) =$
 $0,1580 + 0,1087 + 0,1916 = \mathbf{0,4583}$
- e). $\text{Score}(C_5) = (0,55 \times 0,0232) + (0,25 \times 0,7165) + (0,20 \times 0,8674) =$
 $0,0128 + 0,1791 + 0,1735 = \mathbf{0,3654}$

4.4 Analisis Hasil Perhitungan

Tabel 4.6 Matriks Hasil Akhir Eksekusi Perankingan

Urutan	ID	Nama Konten	Cosine Score	Freshness Score	Quality Score	Skor Final Hibrida
1	C1	Template AI Coding Assistant	0,9026	0,9200	0,9065	0,9077

Tabel 4.6 Matriks Hasil Akhir Eksekusi Perankingan (Lanjutan)

Urutan	ID	Nama Konten	Cosine Score	Freshness Score	Quality Score	Skor Final Hibrida
2	C3	<i>Pitch Deck Template</i>	0,6975	0,6065	0,8482	0,7048
3	C4	Tutorial Manajemen Bisnis untuk UMKM	0,2872	0,4346	0,9580	0,4583
4	C2	Template Desain Logo Modern	0,1160	0,8465	0,7910	0,4336
5	C5	<i>Template Laporan Keuangan Tahunan</i>	0,0232	0,7165	0,8674	0,3654

Berdasarkan hasil komputasi pada Tabel 4.6, akurasi pencocokan algoritma dapat divalidasi secara semantik. Objek C1 menempati peringkat teratas karena berhasil mencetak keunggulan simultan pada ketiga pilar: topik konten sangat selaras dengan minat utama arketipe pengguna (*Technology* dan *Education*), berstatus baru (6 jam), dan memiliki nilai retensi keterlibatan yang tinggi. Kasus paling menarik ditunjukkan oleh objek C4. Meskipun C4 memiliki *Quality Score*

tertinggi (0,9580) akibat akumulasi interaksi massal, posisinya tertahan di peringkat ketiga. Hal ini membuktikan bahwa pembobotan dominan pada *Cosine Similarity* (55%) berhasil mencegah bias popularitas (*rich-get-richer*); sistem tetap memprioritaskan kecocokan minat personalitas individu di atas popularitas global. Sebaliknya, objek C2 yang topiknya kurang relevan tetap mampu bersaing di atas C5 karena tertolong oleh faktor kebaruan (12 jam vs 24 jam), membuktikan bahwa pilar *Freshness* berhasil memberikan ruang eksposur bagi konten baru.