

**IMPLEMENTASI *TIME-AWARE HYBRID RANKING SYSTEM*
MENGUNAKANAN PENDEKATAN *CONTENT SIMILARITY*
DAN *ENGAGEMENT METRICS* UNTUK PERSONALISASI
KONTEN *AI GENERATIF* (STUDI KASUS : PT. PERKASA
TAMA TEKNIK)**

PROPOSAL SKRIPSI

Diajukan untuk Memenuhi Persyaratan Akademis dalam Menyelesaikan Program Sarjana Strata
Satu pada Program Studi Teknik Informatika

Universitas Catur Insan Cendekia

Oleh :

Ade Oktaviano Arrahman (20221020009)



UCIC
UNIVERSITAS
CATUR INSAN CENDEKIA

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS CATUR INSAN CENDEKIA
CIREBON
2026**

1. PENDAHULUAN

1.1. Latar Belakang

Perkembangan pesat ekosistem digital mendorong peningkatan volume produksi data secara eksponensial, khususnya pada platform penyedia layanan konten seperti *template* dan *prompt* kecerdasan buatan (AI). Ekspansi data yang masif ini di satu sisi memberikan variasi pilihan bagi pengguna, namun di sisi lain memicu tantangan besar berupa *information overload* atau kelebihan muatan informasi di era digital [1]. Dalam kondisi ini, sistem rekomendasi telah muncul sebagai alat esensial untuk membantu pengguna menavigasi lautan opsi dan menemukan informasi yang terpersonalisasi secara cepat [1].

Penerapan sistem kurasi konten konvensional saat ini sering kali terbentur pada dilema antara relevansi dan kebaruan. Banyak sistem rekomendasi klasik yang berasumsi bahwa data historis bersifat stasioner, sehingga gagal memperhitungkan sifat dinamis dari perubahan preferensi pengguna seiring berjalannya waktu [2]. Di sisi lain, sistem yang bertumpu murni pada popularitas menyebabkan hanya sebagian kecil item yang diperhatikan, sehingga beberapa item mendapatkan porsi perhatian yang sangat tidak proporsional (*disproportionate attention*) [3]. Akibatnya, konten-konten lama yang sudah viral akan terus mendominasi (*rich-get-richer*), padahal sistem rekomendasi seharusnya dapat berfungsi untuk meningkatkan visibilitas produk atau konten yang kurang dikenal agar persaingan lebih adil [3].

Hal ini menunjukkan bahwa dimensi waktu (*temporality*) sangat penting untuk dipertimbangkan guna menangkap perubahan minat pengguna dari waktu ke waktu, salah satunya dengan memanfaatkan teknik seperti fungsi peluruhan (*decay functions*) [4]. Waktu terbukti merupakan salah satu faktor paling berpengaruh yang mendikte preferensi pengguna [5].

Kebaruan (*freshness*) dari sebuah konten memiliki masa kedaluwarsa relevansi, sehingga pendekatan yang mengintegrasikan fungsi peluruhan (*decay function*) pada tanggal rilis konten menjadi sangat krusial untuk mencegah keusangan informasi di halaman utama pengguna [5].

Dalam konteks pengelolaan distribusi konten tersebut, penelitian ini mengusulkan pengembangan arsitektur *Time-Aware Hybrid Ranking System* pada layanan *backend*. Sistem ini dirancang untuk menstrukturkan ulang algoritma *For You Page* (FYP) dengan memadukan pilar metrik secara seimbang: kemiripan minat pengguna (*Content Similarity*), kualitas interaksi historis (*Engagement Metrics*), dan penalti usia konten berbasis peluruhan eksponensial (*Exponential Time Decay*). Melalui integrasi pembobotan hibrida ini, diharapkan sistem tidak hanya mampu memprediksi preferensi pengguna secara akurat, tetapi juga menciptakan ekosistem platform yang adil dan dinamis bagi distribusi konten-konten terbaru.

1.2. Identifikasi Masalah

Berdasarkan latar belakang di atas, identifikasi masalah dalam penelitian ini adalah:

1. Kesulitan pengguna dalam menemukan konten yang spesifik dan relevan akibat tingginya volume data pada platform.
2. Adanya bias popularitas pada sistem *feed* konvensional, yang menyebabkan konten baru tenggelam oleh konten lama yang sudah memiliki matriks interaksi tinggi.
3. Dibutuhkannya sebuah algoritma perankingan (*ranking algorithm*) yang ringan, efisien, dan mampu menyeimbangkan antara minat personal (*interest*), kualitas konten (*quality*), dan kebaruan (*freshness*).

1.3. Rumusan Masalah

Berdasarkan latar belakang di atas, identifikasi masalah dalam penelitian ini adalah:

1. Kesulitan pengguna dalam menemukan konten yang spesifik dan relevan akibat tingginya volume data pada platform.
2. Adanya bias popularitas pada sistem *feed* konvensional, yang menyebabkan konten baru tenggelam oleh konten lama yang sudah memiliki matriks interaksi tinggi.
3. Dibutuhkannya sebuah algoritma perankingan (*ranking algorithm*) yang ringan, efisien, dan mampu menyeimbangkan antara minat personal (*interest*), kualitas konten (*quality*), dan kebaruan (*freshness*).

1.4. Batasan Masalah

Agar penelitian ini lebih terarah dan fokus, maka ditetapkan batasan masalah sebagai berikut:

1. Pengembangan layanan untuk sistem perankingan ini diimplementasikan menggunakan bahasa pemrograman Golang.
2. Perhitungan *Content Similarity* dilakukan menggunakan algoritma *Cosine Similarity* yang membandingkan vektor preferensi kategori pengguna dengan vektor kategori konten.
3. Fungsi kebaruan (*Time-Aware*) dihitung menggunakan metode peluruhan eksponensial (*Exponential Time Decay*) dengan asumsi waktu paruh (*half-life*) 72 jam.
4. Parameter *Engagement Metrics* yang digunakan difokuskan pada rata-rata penilaian, Riwayat tontonan dan jumlah suka yang dinormalisasi.

1.5. Tujuan Penelitian

Tujuan dari penelitian ini adalah:

1. Merancang dan mengimplementasikan algoritma *Time-Aware Hybrid Ranking System* untuk fitur personalisasi *feed* pada arsitektur *backend* platform konten.
2. Mengukur dan mengevaluasi bagaimana penggabungan bobot *Content Similarity*, *Engagement Metrics*, dan fungsi *Time Decay* dapat menghasilkan urutan rekomendasi konten yang relevan, dinamis, dan adil bagi kreator konten baru.

1.6. Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:


1. Meningkatkan pengalaman pengguna (*user experience*) dalam mengeksplorasi katalog data. Pengguna dapat dengan mudah menemukan *template* atau *prompt* AI yang sangat relevan dengan minat personal mereka tanpa harus mengalami kelebihan muatan informasi (*information overload*).
2. Dapat dijadikan sebagai rujukan dasar (*baseline*) atau studi kasus lanjutan bagi peneliti lain yang ingin mengembangkan algoritma perankingan hibrida yang lebih kompleks, misalnya dengan menambahkan pemrosesan bahasa alami (NLP) atau jaringan saraf tiruan (*Neural Networks*).
3. Menciptakan ekosistem distribusi konten yang lebih adil (*exposure fairness*). Dengan adanya fungsi *Time-Aware*, algoritma ini memastikan bahwa karya atau unggahan terbaru dari kreator (meskipun belum populer) tetap mendapatkan kesempatan tayang di halaman utama.

1.7. Gambaran Sistem

Sistem perankingan yang diusulkan beroperasi dalam dua fase utama: *Candidate Generation* dan *Hybrid Scoring*. Pada fase pertama, sistem mengambil maksimal 300 kandidat konten dari tiga *pool* yang berbeda: konten berdasarkan minat kategori pengguna, konten yang sedang *trending* secara global, dan konten-konten paling baru.

Setelah kandidat digabungkan dan duplikasinya dihapus, sistem masuk ke fase penilaian (*scoring*). Skor akhir setiap konten dihitung secara paralel menggunakan tiga pilar: nilai *Cosine Similarity* (bobot 55%), nilai peluruhan waktu atau *Freshness* (bobot 25%), dan kualitas metrik interaksi (bobot 20%). Hasil akhir dari perhitungan ini akan diurutkan dari skor tertinggi untuk dikembalikan sebagai *respons feed* kepada pengguna.

Gambar 1.7. Gambaran Sistem



2. LANDASAN TEORI

2.1. Tinjauan Pustaka

Sebagai landasan yang komprehensif, bagian ini menguraikan perkembangan studi terdahulu yang sejalan dengan fokus penelitian penulis. Kajian literatur ini bertujuan untuk menjadi tolak ukur perbandingan serta memvalidasi kebaruan dari sistem yang dikembangkan. Berikut disajikan ringkasan dari empat literatur utama yang menjadi rujukan:

Tabel 2.1. Hasil Penelitian Terdahulu

No.	Peneliti (Tahun)	Judul Penelitian	Metode	Hasil/Kesimpulan
1.	Rostami et al. (2022) [6]	A Novel Time-Aware Food Recommender-System...	Deep Learning & Graph Clustering	Membuktikan bahwa penggunaan <i>time-aware similarity measure</i> sangat krusial untuk menangani perubahan ketertarikan pengguna dari waktu ke waktu.
2.	SAI Org (2022) [7]	<i>Exponential Decay Function-Based Time-Aware Recommender System...</i>	<i>Exponential Decay Function</i>	Menunjukkan bahwa <i>Exponential Decay</i> efektif menangani preferensi pengguna yang diekstraksi dari <i>implicit feedback</i> (interaksi tanpa <i>rating</i> langsung).
3.	Liu et al. (2022) [8]	<i>TD-DNN: A Time Decay-Based Deep Neural Network...</i>	<i>Time Decay & Deep Neural Network</i>	Menegaskan bahwa perankingan yang mengabaikan faktor waktu (<i>time decay</i>) akan menghasilkan rekomendasi usang, sehingga

				penambahan metrik waktu wajib dilakukan.
4.	Pilgram et al. (2025) [9]	<i>A consensus privacy metrics...</i>	<i>Time-Based Decay Function</i>	Menggunakan <i>decay function</i> untuk memotong/mengurangi bobot preferensi pengguna di masa lampau agar sistem rekomendasi lebih dinamis.

Berdasarkan beberapa penelitian terdahulu, dapat diidentifikasi adanya beberapa perbedaan mendasar antara penelitian ini dengan penelitian sebelumnya.

Pertama, perbedaan terlihat pada pendekatan metode yang digunakan dalam proses kalkulasi rekomendasi. Penelitian terdahulu banyak menggunakan pendekatan model generatif atau prediktif seperti *Matrix Factorization*, *Deep Learning* (CNN), hingga *Graph Clustering*. Pada penelitian ini, penulis memilih menggunakan pendekatan perankingan hibrida multi-tahap (*multi-stage hybrid ranking*) yang lebih ringan dan deterministik. Sistem menggabungkan *Cosine Similarity* murni berbasis vektor kategori dengan perhitungan normalisasi interaksi pengguna. Pemilihan metode ini didasarkan pada kebutuhan arsitektur *backend* yang menuntut latensi rendah dan efisiensi komputasi tinggi untuk menyajikan *feed* secara *real-time*.

Kedua, perbedaan juga terletak pada fokus penanganan dimensi waktu (*temporal dimension*). Sebagian penelitian sebelumnya menggunakan faktor waktu untuk sekadar mendeteksi pergeseran minat pengguna (*concept-drifting*) pada algoritma *Collaborative Filtering*. Sementara itu, penelitian ini secara khusus menggunakan waktu sebagai pilar independen (Skor *Freshness*) melalui implementasi fungsi *Exponential Time Decay*. Pendekatan ini bertujuan untuk memberikan "penalti usia" pada konten lama, sehingga algoritma tidak hanya melayani preferensi pengguna, tetapi juga secara aktif memberikan visibilitas yang adil bagi konten-konten baru untuk bersaing di halaman utama.

Ketiga, penelitian ini membedakan diri dalam cara memproses dan mengkuantifikasi metrik interaksi (*engagement metrics*). Banyak literatur terdahulu yang masih mengandalkan data interaksi eksplisit (*explicit feedback*) seperti *rating* skala 1 hingga 5. Sebaliknya, penelitian ini berfokus pada ekstraksi nilai dari *implicit feedback* yang dinormalisasi. Metrik interaksi yang kompleks seperti jumlah penggunaan templat (*Used/Recreate Count*), jumlah tayangan (*Watch Count*), dan jumlah suka (*Like Count*) disintesis menjadi satu skor "Kualitas" terpadu, yang lebih akurat merepresentasikan lanskap interaksi pada platform penyedia konten modern.

Keempat, penelitian ini memposisikan sistem rekomendasi bukan hanya sebagai alat untuk memaksimalkan akurasi prediksi, melainkan sebagai ekosistem penemuan konten yang sehat. Berbeda dengan penelitian sebelumnya yang kerap didorong semata-mata oleh tingkat akurasi (yang sering kali berujung pada fenomena *filter bubble* atau *rich-get-richer*), penelitian ini menekankan keseimbangan (*trade-off*)

antara personalisasi dan kebaruan. Dengan menggabungkan *Cosine Similarity* dan *Time Decay*, sistem yang dibangun diharapkan mampu memberikan *feed* yang relevan secara personal sekaligus menjaga keberagaman konten bagi pengguna.

2.2. Dasar Teori

2.2.1. Sistem Rekomendasi

Sistem rekomendasi merupakan perangkat lunak dan teknik algoritmik yang dirancang untuk memberikan saran (*suggestions*) berupa item atau konten yang diprediksi paling relevan dan berguna bagi pengguna tertentu [12]. Di era digital dengan pertumbuhan data yang eksponensial, sistem ini menjadi solusi fundamental untuk mengatasi masalah kelebihan muatan informasi (*information overload*), sehingga pengguna tidak perlu menelusuri seluruh katalog konten secara manual [11]. Lebih jauh lagi, implementasi sistem rekomendasi telah terbukti menjadi instrumen pendukung keputusan yang sangat esensial di berbagai ekosistem, termasuk pada ranah akademik institusional. Hal ini sejalan dengan penelitian Asfi & Fitrianingsih (2020) yang membuktikan bahwa algoritma sistem rekomendasi (seperti *classifier*) dapat difungsikan untuk menyelesaikan permasalahan subjektivitas, contohnya dalam merekomendasikan dosen pembimbing skripsi secara objektif dan akurat [10]. Di ranah kecerdasan buatan (AI) lainnya, efektivitas algoritma komputasi juga dibuktikan oleh penelitian Jacob, Subagio, dan Nursetyo (2025) yang menggunakan pendekatan Rule-Based Expert System sebagai sistem pakar penunjang keputusan yang presisi dan berjalan secara otomatis [19].

Secara tradisional, paradigma sistem rekomendasi diklasifikasikan ke dalam dua pendekatan utama, yaitu [11]:

1. *Content-Base Filtering* (CBF)

Pendekatan ini merekomendasikan item berdasarkan kemiripan atribut atau metadata dari item tersebut dengan profil preferensi pengguna di masa lalu. Dalam konteks platform konten, algoritma ini akan merekomendasikan sebuah konten jika kategori atau fitur konten tersebut memiliki kemiripan (*similarity*) yang tinggi dengan konten-konten yang sebelumnya sering diinteraksikan oleh pengguna.

2. *Collaborative Filtering* (CF)

Pendekatan ini tidak bergantung pada atribut konten, melainkan pada pola historis interaksi (seperti pemberian peringkat atau klik) dari sekumpulan pengguna. CF merekomendasikan item yang disukai oleh pengguna lain yang memiliki profil selera atau perilaku yang serupa dengan pengguna target.

Meskipun kedua metode tersebut populer, masing-masing memiliki keterbatasan yang signifikan. Pendekatan CF sangat rentan terhadap masalah *cold-start* (ketidakmampuan memberikan rekomendasi ketika sistem memiliki pengguna atau item baru yang belum memiliki riwayat interaksi) serta masalah matriks data yang renggang (*data sparsity*) [3]. Di sisi lain, CBF sering kali terjebak pada masalah spesialisasi berlebihan (*overspecialization*), di mana pengguna hanya akan

direkomendasikan jenis konten yang sama secara berulang-ulang tanpa adanya variasi penemuan baru [13].

Untuk mengatasi keterbatasan dari pendekatan-pendekatan tunggal tersebut, dikembangkanlah konsep **Hybrid Recommender System** (Sistem Rekomendasi Hibrida) [13]. Sistem hibrida bekerja dengan menggabungkan dua atau lebih teknik rekomendasi untuk memaksimalkan kelebihan dan meminimalkan kelemahan masing-masing metode [13]. Pada penelitian ini, konsep hibrida diimplementasikan dengan memadukan pencocokan preferensi minat pengguna berbasis kategori konten (*Content Similarity*), yang selanjutnya diperkaya dan dibobotkan bersama metrik interaksi kualitas (*Engagement Metrics*) serta fitur kontekstual berupa dinamika waktu rilis konten (*Time-Aware Ranking*). Penggabungan ini bertujuan untuk menghasilkan peringkat *feed* yang sangat terpersonalisasi namun tetap menjaga kebaruan (*freshness*) informasi bagi pengguna.

2.2.2. Arsitektur Sistem Rekomendasi Dua Tahap (*Two-Stage Recommender System*)

Dalam implementasi sistem rekomendasi berskala besar, mengevaluasi dan menghitung skor kecocokan (seperti algoritma *Cosine Similarity* dan *Time Decay*) pada seluruh populasi data konten untuk setiap permintaan pengguna akan memakan biaya komputasi yang sangat besar dan mengakibatkan latensi yang tidak dapat diterima [12]. Untuk mengatasi tantangan skalabilitas tersebut, arsitektur sistem rekomendasi modern umumnya memecah proses pemfilteran ke dalam desain pipa data (*pipeline*) dua tahap:

Pembangkitan Kandidat (*Candidate Generation*) dan Perankingan (*Ranking/Scoring*) [12], [11].

1. Tahap Pembangkitan Kandidat (*Candidate Generation*)

Fase pertama ini berfungsi sebagai corong penyaring awal (*funnel*) yang bertujuan untuk mereduksi ruang lingkup pencarian secara masif. Sistem menyeleksi jutaan entri dalam basis data menjadi himpunan kandidat berukuran kecil (ratusan item) secara cepat dan komputasional murah [11]. Dalam konteks arsitektur hibrida, pengumpulan kandidat sering kali dilakukan dengan mengambil item dari berbagai *pool* atau strategi pencarian yang berjalan secara paralel untuk mencegah isolasi preferensi pengguna atau *filter bubble* [13]. Pada sistem yang diusulkan, kandidat diekstraksi dari tiga himpunan utama:

1. Kandidat berdasarkan metrik interaksi global tertinggi (*Trending-based*).
2. Kandidat berdasarkan ketertarikan kategori historis pengguna (*Interest-based*).
3. Kandidat berdasarkan unggahan paling mutakhir (*Freshness-based*). Seluruh kandidat dari berbagai sumber ini kemudian digabungkan (*merged*) dan dieliminasi duplikasinya sebelum masuk ke fase berikutnya [13].

2. Tahap Perankingan (*Ranking/Scoring*)

Fase kedua berfokus pada presisi dan penilaian mendalam terhadap himpunan kandidat terbatas yang telah lolos dari fase pertama [12]. Karena jumlah data yang diproses sudah jauh lebih kecil, sistem dapat menerapkan kalkulasi matematis komposit yang lebih berat untuk menentukan skor relevansi absolut dari setiap konten. Pada tahap inilah pilar algoritma hibrida utama dioperasikan secara bersamaan [13]. Setiap kandidat dinilai berdasarkan tingkat kemiripan vektor kategorinya (*Content Similarity*), kualitas interaksi historisnya (*Engagement Metrics*), serta penalti peluruhan waktu (*Time-Awareness*). Konten yang memiliki skor gabungan hibrida tertinggi akan diurutkan secara menurun (*descending*) untuk dipresentasikan sebagai daftar rekomendasi akhir atau *For You Page* (FYP) kepada pengguna [11], [13]. Pendekatan penilaian dan perankingan berbasis multi-atribut ini sejalan dengan penelitian Andika, Kusnadi, dan Sokibi (2020), yang membuktikan bahwa metode komputasi pembobotan multi-kriteria sangat efektif untuk menghasilkan keputusan rekomendasi yang objektif dan presisi [22].

2.2.3. *Cosine Similarity*

Cosine Similarity adalah salah satu metrik pengukuran jarak (*distance metric*) yang paling masif dieksploitasi dalam sistem pemfilteran berbasis konten (*Content-Based Filtering*) untuk mengevaluasi derajat kesamaan antara dua profil atau entitas [11]. Metrik ini tidak berfokus pada pengukuran selisih besaran ukuran (*magnitude*) antara dua profil, melainkan mengukur nilai kosinus sudut yang terbentuk di antara dua

vektor tak nol di dalam sebuah ruang multidimensi (*multidimensional vector space*) [14].

Dalam konteks arsitektur sistem rekomendasi yang dikembangkan pada penelitian ini, algoritma *Cosine Similarity* secara spesifik diimplementasikan untuk mengkalkulasi tingkat relevansi antara vektor preferensi kategori milik pengguna (U) terhadap vektor atribut kategori yang merepresentasikan sebuah objek konten (C) [11]. Secara matematis, formulasi dari *Cosine Similarity* didefinisikan melalui persamaan berikut [14]:

Gambar 2.1. Rumus Cosine Similarity

$$\text{sim}(U, C) = \cos(\Theta) = \frac{U \cdot C}{\|U\| \|C\|} = \frac{\sum_{i=1}^n U_i C_i}{\sqrt{\sum_{i=1}^n U_i^2} \sqrt{\sum_{i=1}^n C_i^2}}$$

Keterangan persamaan di atas adalah sebagai berikut:

1. U_i merepresentasikan nilai bobot ketertarikan pengguna terhadap kategori ke- i (didapatkan dari riwayat interaksi pengguna).
2. C_i merepresentasikan keberadaan (*boolean*) atau bobot kategori ke- i yang melekat pada objek konten kandidat.
3. n mewakili total dimensi dari ruang vektor, yang ekuivalen dengan jumlah keseluruhan variasi kategori yang terdaftar di dalam sistem basis data.

Hasil dari perhitungan ruang vektor ini selalu menghasilkan metrik berskala dengan rentang nilai antara 0 hingga 1. Jika skor yang diproduksi mendekati nilai 1, kondisi tersebut mengindikasikan bahwa sudut antar vektor sangatlah sempit ($\theta \approx 0^\circ$), yang secara semantik berarti konten kandidat memiliki tingkat kemiripan atau kecocokan selera yang sangat identik dengan riwayat pengguna [4]. Sebaliknya, apabila skor yang dihasilkan mendekati atau sama dengan 0, kedua vektor diasumsikan saling tegak lurus (*orthogonal*), yang menegaskan ketiadaan irisan korelasi antara profil minat pengguna dengan kategori konten yang tengah dievaluasi [14]. Dalam kalkulasi perankingan hibrida yang diusulkan, metrik *Cosine Similarity* ini diposisikan sebagai pilar *Interest-Based* utama pembentuk skor akhir konten.

2.2.4. *Time-Aware Ranking dan Exponential Time Decay*

Sistem rekomendasi tradisional umumnya berasumsi bahwa preferensi pengguna dan relevansi sebuah item bersifat statis dari waktu ke waktu. Namun, pada platform penyedia konten yang dinamis, asumsi ini tidak lagi relevan [15]. Preferensi pengguna dapat bergeser, dan kebaruan (*novelty*) dari sebuah konten memiliki masa kedaluwarsa. Oleh karena itu, diperkenalkanlah paradigma *Time-Aware Recommender System* (TARS), yaitu sistem yang secara eksplisit memodelkan waktu sebagai dimensi kontekstual tambahan dalam proses perankingan [15].

Salah satu teknik paling efektif dan komputasional ringan untuk mengimplementasikan TARS adalah melalui penggunaan fungsi peluruhan waktu atau *Time Decay Function* [16]. Secara khusus, *Exponential Time Decay* (peluruhan

eksponensial) memberikan penalti (pengurangan nilai) secara mulus pada skor relevansi sebuah item berdasarkan usianya [16]. Pendekatan ini memastikan bahwa item yang baru dipublikasikan memiliki keunggulan visibilitas sementara, yang secara perlahan akan menyusut seiring berjalannya waktu, sehingga mencegah dominasi konten lama di halaman rekomendasi.

Sesuai dengan implementasi arsitektur sistem pada penelitian ini, skor kebaruan konten (*Freshness Score*) dihitung menggunakan persamaan peluruhan eksponensial berikut [16]:

Gambar 2.2. Persamaan Peluruhan Eksponensial

$$S_{time} = e^{-\left(\frac{\Delta t}{\lambda}\right)}$$

Keterangan dari persamaan di atas adalah:

1. S_{time} adalah skor kebaruan akhir yang akan berkisar antara 0 hingga 1.
2. e adalah konstanta bilangan Euler (≈ 2.71828).
3. Δt adalah usia konten atau selisih antara waktu saat ini dengan waktu konten dibuat, yang direpresentasikan dalam satuan jam (*hours*).
4. λ adalah konstanta waktu paruh (*half-life parameter*) yang mengontrol seberapa curam kurva peluruhan terjadi. Pada penelitian ini, nilai λ ditetapkan sebesar 72.0 (mewakili 72 jam atau 3 hari), yang berarti konten akan kehilangan sebagian besar bobot kebaruannya secara signifikan setelah melewati siklus 3 hari.

Melalui integrasi fungsi peluruhan ini, sistem *hybrid* tidak hanya melayani kecocokan minat (*interest-based*), tetapi juga secara proaktif mendistribusikan eksposur (*exposure*) yang adil bagi konten-konten yang baru diunggah [15], [16].

2.2.5. Engagement Metrics dan Normalisasi Data

Selain kecocokan minat dan kebaruan waktu, kualitas intrinsik dari sebuah konten harus dievaluasi untuk memastikan bahwa sistem merekomendasikan item yang berharga. Evaluasi ini dilakukan dengan mengekstraksi *Engagement Metrics* (metrik keterlibatan), yaitu kumpulan sinyal interaksi historis pengguna terhadap konten tersebut [11]. Sinyal interaksi ini dapat berupa umpan balik eksplisit (*explicit feedback*) seperti rata-rata penilaian, maupun umpan balik implisit (*implicit feedback*) seperti jumlah klik, jumlah tayangan, penggunaan templat, dan jumlah suka [11].

Dalam membangun formula sistem hibrida, penggabungan langsung nilai *Engagement Metrics* (yang batas atasnya tidak terhingga, contohnya jumlah 'Suka' yang bisa mencapai puluhan ribu) dengan skor probabilitas seperti *Cosine Similarity* (yang bernilai 0 hingga 1) akan menyebabkan ketidakseimbangan model (*model bias*) [14]. Variabel dengan rentang nilai absolut yang jauh lebih besar akan mendominasi dan mengabaikan variabel lainnya [14].

Untuk menanggulangi ketimpangan ini, diperlukan teknik pra-pemrosesan data berupa **Normalisasi** (*Data Normalization*). Pada penelitian ini, teknik normalisasi penskalaan maksimum absolut (*Max-Absolute Scaling* atau turunan dari *Min-Max Normalization*) diterapkan untuk memampatkan nilai interaksi mentah ke dalam skala rasio homogen antara 0 hingga 1 [14]. Persamaan normalisasi tersebut

didefinisikan sebagai:

Gambar 2.3. Persamaan Peluruhan Eksponensial

$$x_{norm} = \frac{X_i}{X_{max}}$$

Di mana X adalah nilai interaksi konten saat ini (misalnya jumlah suka dari sebuah postingan), dan X_{max} adalah nilai interaksi tertinggi dari seluruh himpunan kandidat yang sedang diproses pada ruang pencarian yang sama [14]. Hasil dari normalisasi metrik ini kemudian dikombinasikan (menjadi parameter *Quality Score*) bersama skor kemiripan dan skor kebaruan untuk menghasilkan nilai *ranking* hibrida yang terkalibrasi secara seimbang.

3. METODOLOGI PENELITIAN

3.1. Tinjauan Pustaka

Dalam pelaksanaan penelitian dan pengembangan arsitektur *Time-Aware Hybrid Ranking System* ini, penulis menggunakan sejumlah bahan berupa spesifikasi data serta perangkat keras dan perangkat lunak sebagai alat penunjang operasional penelitian.

3.1.1. Bahan Penelitian

Objek utama yang digunakan dalam penelitian ini adalah *dataset* yang merepresentasikan entitas, relasi, dan rekam jejak interaksi (*engagement*) pengguna pada sebuah platform konten. Dikarenakan penelitian ini berpusat pada optimasi algoritma di sisi *backend*, basis data yang digunakan mencakup data operasional maupun data sintetis (*synthetic data*) yang dirancang khusus untuk menyimulasikan beban kerja lingkungan produksi (*production environment*). Klasifikasi spesifikasi data tersebut diuraikan sebagai berikut:

1. Data Metadata Konten

Merupakan atribut fundamental yang mendefinisikan identitas suatu item konten. Entitas ini mencakup identifikasi unik, atribut deskriptif, serta parameter temporal berupa *timestamp* publikasi. Parameter temporal ini diposisikan sebagai variabel penentu yang krusial dalam mengkalkulasi penalti usia konten melalui fungsi peluruhan eksponensial (*Exponential Time Decay*).

2. Data Kategori dan Vektor Preferensi Pengguna

Merupakan data relasional yang memetakan afiliasi suatu konten terhadap entitas kategori tertentu, sekaligus merepresentasikan matriks ketertarikan historis pengguna terhadap kategori tersebut. Data ini difungsikan sebagai parameter masukan komputasi (*computational input*) untuk membentuk representasi ruang vektor dalam kalkulasi algoritma *Cosine Similarity*

3. Data Metrik Interaksi (*Engagement Metrics*)

Merupakan himpunan variabel kuantitatif yang merekam umpan balik perilaku pengguna (*user behavioral feedback*), baik secara eksplisit maupun implisit. Variabel turunan ini diekstraksi dari akumulasi metrik seperti frekuensi tayangan (*Watch Count*), tingkat adopsi templat (*Used/Recreate Count*), presensi preferensi (*Like Count*), serta nilai rata-rata ulasan (*Rating Avg*). Seluruh atribut kuantitatif ini selanjutnya akan dinormalisasi guna merumuskan rasio kualitas interaksi konten secara proporsional.

3.1.2. Alat Penelitian

Instrumen penelitian yang digunakan mencakup seluruh infrastruktur komputasi, baik pada lapis perangkat keras (*hardware*) maupun perangkat lunak (*software*). Infrastruktur ini difungsikan untuk memfasilitasi tahapan perancangan arsitektur, implementasi kode sumber (*source code*), hingga simulasi pengujian kinerja algoritma perankingan pada lingkungan pengembangan lokal (*local development environment*).

1. Perangkat Keras (*Hardware*)

Perangkat keras diposisikan harus mampu menopang beban komputasi konkuren, dan pemrosesan basis data relasional. Untuk mendukung latensi rendah dan throughput tinggi pada lingkungan produksi nyata, arsitektur backend ini ke depannya dikembangkan menggunakan mekanisme load balancing. Hal ini merujuk

pada penelitian Subagio, Hatta, dan Asih (2021) yang membuktikan bahwa metode tersebut sangat esensial untuk mendistribusikan beban web server secara terstruktur dan real-time [20]. Spesifikasi instrumen fisik yang dialokasikan dalam penelitian ini adalah:

1. Unit Pemrosesan Pusat (CPU)

Komputer berbasis arsitektur *x86_64* (Macintosh berbasis prosesor Intel) yang bertindak sebagai mesin utama untuk menjalankan kompilasi program.

2. Memori Utama (*Random Access Memory* / RAM)

Kapasitas memori yang memadai dialokasikan guna menjamin kelancaran alokasi sumber daya (*resource allocation*) saat menjalankan sistem operasi tamu (*guest OS*), eksekusi konkurensi bahasa Go (*Goroutines*), serta simulasi *server* basis data secara bersamaan tanpa memicu *memory bottleneck*.

3. Media Penyimpanan (*Solid State Drive* / SSD)

Penggunaan penyimpanan berbasis memori kilat (*flash-based storage*) diimplementasikan untuk meminimalisasi latensi *Input/Output* (I/O). Tingkat latensi I/O yang rendah sangat krusial dalam mempercepat waktu respons kueri agregasi basis data yang kompleks pada fase penarikan kandidat (*Candidate Generation*).

2. Perangkat Lunak (*Software*)

Perangkat lunak merupakan instrumen logikal yang digunakan sepanjang siklus pengembangan perangkat lunak (*Software Development Life Cycle*).

Lingkungan komputasi dan tumpukan teknologi (*tech stack*) yang digunakan diuraikan sebagai berikut:

1. Sistem Operasi dan Lapisan Virtualisasi

Sistem operasi macOS digunakan sebagai lingkungan komputasi utama (*primary environment*). Sistem operasi ini memfasilitasi seluruh tahapan pengembangan secara *native*, mulai dari penulisan kode sumber, kompilasi program, eksekusi layanan basis data, hingga simulasi *server* lokal untuk pengujian

API. Bahasa Pemrograman dan Kompilator

Compiler bahasa pemrograman Go (Golang) versi mutakhir. Bahasa ini dipilih secara spesifik karena karakteristiknya yang dikompilasi secara statis (*statically compiled*) serta memiliki manajemen konkurensi yang tangguh, menjadikannya sangat ideal untuk memproses algoritma perankingan hibrida yang menuntut latensi rendah (*low-latency*) secara eksekusi langsung (*on-the-fly*).

2. Sistem Manajemen Basis Data

Perangkat lunak basis data relasional yang dioperasikan untuk mengelola persistensi data metadata konten, relasi kategori, dan riwayat interaksi. Sistem ini

juga bertugas mengeksekusi kueri struktural (seperti operasi *JOIN* dan kondisional) pada fase penyaringan kandidat awal.

3. Integrated Development Environment (IDE)

Lingkungan pengembangan terpadu (seperti Visual Studio Code atau GoLand) yang difungsikan sebagai editor sintaks utama, dilengkapi dengan fitur analisis kode statis, *debugging*, serta integrasi sistem kontrol versi (*version control system*).

4. Instrumen Pengujian API (*API Testing and Profiling Tools*)

Perangkat lunak klien API (seperti Postman) dan perangkat lunak pengujian beban (*load testing tools*, seperti Apache JMeter) yang digunakan untuk memvalidasi presisi fungsionalitas *endpoint* perankingan, mengukur metrik Waktu Respons (*Response Time*), dan mengevaluasi kapasitas *Throughput* sistem dalam menangani simulasi permintaan serentak (*concurrent requests*).

3.2. Prosedur Penelitian

Penelitian ini mengadopsi metode rekayasa perangkat lunak yang dipadukan dengan pendekatan riset eksperimental komputasional. Pendekatan ini dipilih untuk memastikan bahwa model matematis algoritma perankingan hibrida yang dirancang tidak hanya valid secara teoretis, tetapi juga tangguh dan optimal ketika diimplementasikan ke dalam arsitektur layanan *backend* (API) yang fungsional.

Tahapan sistematis dalam penelitian ini direpresentasikan melalui diagram alir kerangka kerja, yang kemudian dijabarkan ke dalam 5 (lima) langkah operasional.

Penjabaran dari masing-masing tahapan pada kerangka kerja di atas adalah sebagai berikut:

1. Tahap Identifikasi dan Analisis Kebutuhan Sistem

Tahap inisiasi ini difokuskan pada analisis fundamental mengenai kelemahan algoritma *feed* konvensional (seperti *chronological* murni atau *trending* murni) yang rentan terhadap bias popularitas dan *filter bubble*. Kegiatan utama pada tahap ini mencakup penentuan parameter sistem, yaitu mengidentifikasi variabel ketertarikan (*Interest*), variabel metrik keterlibatan (*Engagement Metrics*), dan variabel temporal (*Time-Awareness*). Selain itu, dilakukan juga perumusan kebutuhan arsitektur layanan *Application Programming Interface* (API) yang akan bertugas menyajikan data secara *real-time* ke sisi klien.

2. Tahap Pengumpulan dan Pra-pemrosesan Data (*Data Preprocessing*)

Tahap ini berfokus pada akuisisi data uji dan transformasi data mentah agar kompatibel dengan lingkungan komputasi algoritma. Proses pra-pemrosesan mencakup dua metrik krusial:

1. Vektorisasi Kategori

Mengonversi data riwayat preferensi pengguna dan entitas kategori konten ke dalam bentuk representasi ruang vektor (*vector space*) sebagai masukan mutlak untuk perhitungan *Cosine Similarity*.

2. Normalisasi Data Interaksi

Menerapkan teknik penskalaan maksimum absolut (*Max-Absolute Scaling*) terhadap nilai agregat interaksi mentah (seperti *Watch Count*, *Used Count*, dan *Like Count*). Proses ini wajib dilakukan untuk menyeragamkan rentang skala kualitas interaksi menjadi rasio 0 hingga 1, sehingga tidak mendominasi variabel lain saat dilakukan pembobotan akhir.

3. Tahap Perancangan Arsitektur Algoritma

Tahap ini merupakan fase inti untuk merancang logika aliran data (*data flow*) pada sistem perankingan. Perancangan mengadopsi pendekatan arsitektur rekomendasi dua tahap (*Two-Stage Recommender System*):

1. Fase Pembangkitan Kandidat (*Candidate Generation*)

Merancang kueri agregasi basis data untuk mengekstraksi dan menyaring ratusan kandidat konten dari tiga himpunan (*pool*) utama, yaitu: himpunan minat kategori, himpunan *trending* global, dan himpunan unggahan terbaru (*freshness*).

2. Fase Kalkulasi Hibrida (*Hybrid Scoring*)

Memformulasikan persamaan matematika yang menggabungkan nilai *Cosine Similarity*, nilai penalti usia konten berbasis peluruhan eksponensial (*Exponential Time Decay*), dan nilai kualitas interaksi yang telah dinormalisasi ke dalam satu nilai komposit akhir (*Final Score*).

3. Tahap Implementasi Sistem

Tahap ini merealisasikan rancangan konseptual dan model algoritmik ke dalam bentuk kode sumber menggunakan bahasa pemrograman Go . Implementasi ini mencakup:

1. Pembuatan antarmuka REST API. Pengembangan arsitektur komunikasi data berbasis web ini sejalan dengan penelitian Sokibi dan Adam (2022), yang membuktikan bahwa perancangan sistem informasi berbasis web sangat efektif dalam mengelola dan mendistribusikan data secara terstruktur dan responsive [21].
2. Integrasi basis data relasional menggunakan eksekusi operasi kueri kompleks (*query context*) untuk fase penarikan kandidat.
3. Eksekusi logika pembobotan, pengurutan iteratif (*sorting*), dan pemotongan jumlah data batasan (*slicing/limit*) secara *on-the-fly* sebelum data dikemas dan didistribusikan dalam format respons JSON.

4. Tahap Evaluasi dan Pengujian Eksperimental

Tahap terakhir ini bertujuan untuk melakukan validasi komprehensif guna mengukur efektivitas dan efisiensi model yang telah diimplementasikan. Evaluasi dipecah menjadi dua metrik pengukuran teknis:

1. Uji Kualitas Relevansi (*Ranking Quality*)

Menyimulasikan berbagai profil perilaku pengguna untuk mengukur tingkat presisi dan akurasi urutan rekomendasi pada halaman *feed*. Kualitas perankingan ini dievaluasi menggunakan standar metrik *Normalized Discounted Cumulative Gain* (NDCG).

2. Uji Kinerja Komputasi (*Performance Testing*)

Melakukan pengujian beban kerja (*load testing*) terhadap layanan. Pengujian ini difokuskan pada pengukuran utilitas Waktu Respons (*Response Time* / Latensi) dalam satuan milidetik, serta kapasitas penyelesaian permintaan serentak (*Throughput*) dalam satuan *requests per second* (RPS) [18].

4. JADWAL PENELITIAN

4.1. Tempat dan Objek Penelitian

4.1.1. Tempat Penelitian

Penelitian dan pengembangan sistem ini dilakukan secara mandiri berbasis komputasi lokal dengan fokus pengembangan sistem. Jika penelitian ini diintegrasikan atau mengambil studi kasus pada instansi/perusahaan tempat praktik di : PT. Tama Perkasa Teknik, maka rincian lokasi penelitian adalah sebagai berikut:

a. Instansi : PT. Tama Perkasa Teknik

b. Alamat : Jl. Sidorejo No. 75A, Kecamatan Dumai Selatan, Kelurahan

Ratu Sima, Kota Dumai, Riau.

- c. Pembimbing : Antoni Tantama Putra
- d. Bagian : Asisten Direktur

4.1.2. Objek Penelitian

Objek utama dalam penelitian ini adalah algoritma perankingan hibrida (*Hybrid Ranking Algorithm*) pada arsitektur *backend*. Secara spesifik, penelitian ini membedah dan mengoptimasi fungsionalitas *Application Programming Interface* (API) yang bertugas menyajikan rekomendasi *feed* terpersonalisasi pada platform penyedia konten (*template* dan *prompt* AI). Data yang menjadi batasan observasi adalah *log* interaksi pengguna (metrik *engagement*), usia konten (*timestamp*), serta metadata kategori konten.

4.2. Tabel Penyelesaian Skripsi

Tabel 4.1. Jadwal Pelaksanaan Penelitian

[illegible]

[illegible]

5. DAFTAR PUSTAKA

- [1] M. S. Chelvam, S. Haw, L. D. Krisnawati, dan A. Mahastama, "Hybrid-Based Recommender System Based on Electronic Product Reviews," *JOIV : International Journal on Informatics Visualization*, vol. 9, no. 4, hal. 1752-1764, 2025.
- [2] E. J. de Borba, I. Gasparini, dan D. Lichtnow, "Time-Aware Recommender Systems: A Systematic Mapping," dalam *International Conference on Human-Computer Interaction*, 2021.
- [3] M. Al-Ghuribi, S. A. Noah, dan S. Tiun, "Hybrid Quality-Based Recommender Systems: A Systematic Literature Review," *IEEE Access*, 2024.
- [4] B. S. B. Contreras dan L. A. Digiampietri, "Evolution of Scientific Interests: A Time-Aware Recommender System," *Anais do Brazilian Workshop on Social Network Analysis and Mining (BraSNAM)*, 2025.
- [5] A. Y. Hassan, E. Fadel, dan N. Akkari, "Exponential Decay Function-Based Time-Aware Recommender System for e-Commerce Applications," *International Journal of Advanced Computer Science and Applications (IJACSA)*, vol. 13, no. 10, 2022.
- [6] M. Rostami *et al.*, "A Novel Time-Aware Food Recommender-System," 2022.
- [7] SAI Org, "Exponential Decay Function-Based Time-Aware Recommender System," 2022.
- [8] Liu *et al.*, "TD-DNN: A Time Decay-Based Deep Neural Network," 2022.
- [9] Pilgram *et al.*, "A consensus privacy metrics," 2025.
- [10] M. Asfi dan N. Fitriarningsih, "Implementasi Algoritma Naive Bayes Classifier sebagai Sistem Rekomendasi Pembimbing Skripsi," *InfoTekJar : Jurnal Nasional Informatika dan Teknologi Jaringan*, vol. 5, no. 1, 2020.
- [11] F. Ricci, L. Rokach, dan B. Shapira, "Recommender systems: introduction and challenges," dalam *Recommender systems handbook*, Boston, MA: Springer, 2015, hal. 1-34.
- [12] F. O. Isinkaye, Y. O. Folajimi, dan B. A. Ojokoh, "Recommendation systems: Principles, methods and evaluation," *Egyptian Informatics Journal*, vol. 16, no. 3, hal. 261-273, 2015.
- [13] E. Çano dan M. Morisio, "Hybrid recommender systems: A systematic literature review," *Intelligent Data Analysis*, vol. 21, no. 6, hal. 1487-1524, 2017.
- [14] J. Han, M. Kamber, dan J. Pei, *Data mining: concepts and techniques*, 3rd ed. Morgan Kaufmann Publishers, 2011.
- [15] P. G. Campos, F. Díez, dan I. Cantador, "Time-aware recommender systems: a comprehensive survey and analysis of existing evaluation protocols," *User Modeling and User-Adapted Interaction*, vol. 24, no. 1-2, hal. 67-119, 2014.
- [16] Y. Ding dan X. Li, "Time weight collaborative filtering," dalam *Proceedings of the 14th ACM international conference on Information and knowledge management (CIKM '05)*, 2005, hal. 485-492.
- [17] K. Järvelin dan J. Kekäläinen, "Cumulated gain-based evaluation of IR techniques," *ACM Transactions on Information Systems (TOIS)*, vol. 20, no. 4, hal. 422-446, 2002.
- [18] I. Sommerville, *Software Engineering*, 10th ed. Pearson, 2015.

- [19] A. Jacob, R. T. Subagio, dan A. Nursetyo, "Perangkat Otomatisasi Pergantian Air Budidaya Ikan Lele Menggunakan Metode Rule Based Expert System," *RIGGS: Journal of Artificial Intelligence and Digital Business*, 2025.
- [20] K. A. Pratama, R. T. Subagio, M. Hatta, dan V. Asih, "Implementasi Load Balancing Pada Web Server Menggunakan Apache Dengan Server Mirror Data Secara Real Time," *Jurnal Digit: Digital of Information Technology*, vol. 11, no. 2, hal. 178-189, 2021.
- [21] U. Khotimah, J. Z. Mutaqin, P. Sokibi, R. Adam, V. Asih, S. Santoso, dan W. Ilham, "Perancangan Sistem Informasi Pelayanan Administrasi Kependudukan Desa Candrajaya Berbasis Web," *Jurnal Pengabdian UCIC*, vol. 1, no. 2, 2022.
- [22] S. G. Andika, K. Kusrandi, dan P. Sokibi, "Sistem Pendukung Keputusan Pemilihan Kegiatan Ekstrakurikuler Untuk Siswa Sma Menggunakan Metode Simple Multi Attribute Rating Technique (Studi Kasus: Sma Santa Maria Cirebon)," *Jurnal Digit: Digital of Information Technology*, vol. 9, no. 1, hal. 59-70, 2020.