

BAB III

LANDASAN TEORI

3.1 Tinjauan Pustaka

Sebagai landasan yang komprehensif, bagian ini menguraikan perkembangan studi terdahulu yang sejalan dengan fokus penelitian penulis. Kajian literatur ini bertujuan untuk menjadi tolok ukur perbandingan serta memvalidasi kebaruan dari sistem yang dikembangkan. Berikut disajikan ringkasan dari empat literatur utama yang menjadi rujukan:

Tabel 3.1. Hasil Penelitian Terdahulu

No.	Peneliti (Tahun)	Judul Penelitian	Metode	Hasil/Kesimpulan
1.	Rostami et al. (2022) [6]	A Novel Time-Aware Food Recommender-System...	Deep Learning & Graph Clustering	Membuktikan bahwa penggunaan <i>time-aware similarity measure</i> sangat krusial untuk menangani perubahan ketertarikan pengguna dari waktu ke waktu.
2.	SAI Org (2022) [7]	<i>Exponential Decay Function-Based Time-Aware Recommender System...</i>	<i>Exponential Decay Function</i>	Menunjukkan bahwa <i>Exponential Decay</i> efektif menangani preferensi pengguna yang diekstraksi dari <i>implicit feedback</i>

Tabel 3.1. Hasil Penelitian Terdahulu

No.	Peneliti (Tahun)	Judul Penelitian	Metode	Hasil/Kesimpulan
				(interaksi tanpa <i>rating</i> langsung).
3.	Liu et al. (2022) [8]	<i>TD-DNN: A Time Decay-Based Deep Neural Network...</i>	<i>Time Decay & Deep Neural Network</i>	Menegaskan bahwa perankingan yang mengabaikan faktor waktu (<i>time decay</i>) akan menghasilkan rekomendasi usang, sehingga penambahan metrik waktu wajib dilakukan
4.	Pilgram et al. (2025) [9]	<i>A consensus privacy metrics...</i>	<i>Time-Based Decay Function</i>	Menggunakan <i>decay function</i> untuk memotong/mengurangi bobot preferensi pengguna di masa lampau agar sistem rekomendasi lebih dinamis.

Berdasarkan beberapa penelitian terdahulu, dapat diidentifikasi adanya beberapa perbedaan mendasar antara penelitian ini dengan penelitian sebelumnya.

Pertama, perbedaan terlihat pada pendekatan metode yang digunakan dalam proses kalkulasi rekomendasi. Penelitian terdahulu banyak menggunakan pendekatan model generatif atau prediktif seperti *Matrix Factorization*, *Deep Learning* (CNN), hingga *Graph Clustering*. Pada penelitian ini, penulis memilih menggunakan pendekatan perankingan hibrida multi-tahap (*multi-stage hybrid ranking*) yang lebih ringan dan deterministik. Sistem menggabungkan *Cosine Similarity* murni berbasis vektor kategori dengan perhitungan normalisasi interaksi pengguna. Pemilihan metode ini didasarkan pada kebutuhan arsitektur *backend*

yang menuntut latensi rendah dan efisiensi komputasi tinggi untuk menyajikan *feed* secara *real-time*.

Kedua, perbedaan juga terletak pada fokus penanganan dimensi waktu (*temporal dimension*). Sebagian penelitian sebelumnya menggunakan faktor waktu untuk sekadar mendeteksi pergeseran minat pengguna (*concept-drifting*) pada algoritma *Collaborative Filtering*. Sementara itu, penelitian ini secara khusus menggunakan waktu sebagai pilar independen (Skor *Freshness*) melalui implementasi fungsi *Exponential Time Decay*. Pendekatan ini bertujuan untuk memberikan "penalti usia" pada konten lama, sehingga algoritma tidak hanya melayani preferensi pengguna, tetapi juga secara aktif memberikan visibilitas yang adil bagi konten-konten baru untuk bersaing di halaman utama.

Ketiga, penelitian ini membedakan diri dalam cara memproses dan mengkuantifikasi metrik interaksi (*engagement metrics*). Banyak literatur terdahulu yang masih mengandalkan data interaksi eksplisit (*explicit feedback*) seperti *rating* skala 1 hingga 5. Sebaliknya, penelitian ini berfokus pada ekstraksi nilai dari *implicit feedback* yang dinormalisasi. Metrik interaksi yang kompleks seperti jumlah penggunaan templat (*Used/Recreate Count*), jumlah tayangan (*Watch Count*), dan jumlah suka disintesis menjadi satu skor Kualitas terpadu, yang lebih akurat merepresentasikan lanskap interaksi pada platform penyedia konten modern.

Keempat, penelitian ini memposisikan sistem rekomendasi bukan hanya sebagai alat untuk memaksimalkan akurasi prediksi, melainkan sebagai ekosistem penemuan konten yang sehat. Berbeda dengan penelitian sebelumnya yang kerap didorong semata-mata oleh tingkat akurasi (yang sering kali berujung pada fenomena *filter bubble* atau *rich-get-richer*), penelitian ini menekankan

keseimbangan (*trade-off*) antara personalisasi dan kebaruan. Dengan menggabungkan *Cosine Similarity* dan *Time Decay*, sistem yang dibangun diharapkan mampu memberikan *feed* yang relevan secara personal sekaligus menjaga keberagaman konten bagi pengguna.

3.2 Dasar Teori

3.2.1 Sistem Rekomendasi

Sistem rekomendasi merupakan perangkat lunak dan teknik algoritmik yang dirancang untuk memberikan saran (*suggestions*) berupa item atau konten yang diprediksi paling relevan dan berguna bagi pengguna tertentu [12]. Di era digital dengan pertumbuhan data yang eksponensial, sistem ini menjadi solusi fundamental untuk mengatasi masalah kelebihan muatan informasi (*information overload*), sehingga pengguna tidak perlu menelusuri seluruh katalog konten secara manual [11]. Lebih jauh lagi, implementasi sistem rekomendasi telah terbukti menjadi instrumen pendukung keputusan yang sangat esensial di berbagai ekosistem, termasuk pada ranah akademik institusional. Hal ini sejalan dengan penelitian Asfi & Fitrianingsih (2020) yang membuktikan bahwa algoritma sistem rekomendasi (seperti *classifier*) dapat difungsikan untuk menyelesaikan permasalahan subjektivitas, contohnya dalam merekomendasikan dosen pembimbing skripsi secara objektif dan akurat [10]. Di ranah kecerdasan buatan (AI) lainnya, efektivitas algoritma komputasi juga dibuktikan oleh penelitian Jacob, Subagio, dan Nursetyo (2025) yang menggunakan pendekatan RuleBased Expert System sebagai sistem pakar penunjang keputusan yang presisi dan berjalan secara otomatis [19]. Secara

tradisional, paradigma sistem rekomendasi diklasifikasikan ke dalam dua pendekatan utama, yaitu [11]:

1. *Content-Base Filtering* (CBF)

Pendekatan ini merekomendasikan item berdasarkan kemiripan atribut atau metadata dari item tersebut dengan profil preferensi pengguna di masa lalu. Dalam konteks platform konten, algoritma ini akan merekomendasikan sebuah konten jika kategori atau fitur konten tersebut memiliki kemiripan (*similarity*) yang tinggi dengan konten-konten yang sebelumnya sering diinteraksikan oleh pengguna.

2. *Collaborative Filtering* (CF)

Pendekatan ini tidak bergantung pada atribut konten, melainkan pada pola historis interaksi (seperti pemberian peringkat atau klik) dari sekumpulan pengguna. CF merekomendasikan item yang disukai oleh pengguna lain yang memiliki profil selera atau perilaku yang serupa dengan pengguna target.

Meskipun kedua metode tersebut populer, masing-masing memiliki keterbatasan yang signifikan. Pendekatan CF sangat rentan terhadap masalah *cold-start* (ketidakmampuan memberikan rekomendasi ketika sistem memiliki pengguna atau item baru yang belum memiliki riwayat interaksi) serta masalah matriks data yang renggang (*data sparsity*) [3]. Di sisi lain, CBF sering kali terjebak pada masalah spesialisasi berlebihan (*overspecialization*), di mana pengguna hanya akan direkomendasikan jenis konten yang sama secara berulang-ulang tanpa adanya variasi penemuan baru [13].

Untuk mengatasi keterbatasan dari pendekatan-pendekatan tunggal tersebut, dikembangkanlah konsep Hybrid Recommender System (Sistem Rekomendasi Hibrida) . Sistem hibrida bekerja dengan menggabungkan dua atau lebih teknik

rekomendasi untuk memaksimalkan kelebihan dan meminimalkan kelemahan masing masing metode . Pada penelitian ini, konsep hibrida diimplementasikan dengan memadukan pencocokan preferensi minat pengguna berbasis kategori konten (*Content Similarity*), yang selanjutnya diperkaya dan dibobotkan bersama metrik interaksi kualitas (*Engagement Metrics*) serta fitur kontekstual berupa dinamika waktu rilis konten (*Time-Aware Ranking*). Penggabungan ini bertujuan untuk menghasilkan peringkat *feed* yang sangat terpersonalisasi namun tetap menjaga kebaruan (*freshness*) informasi bagi pengguna.

Untuk mengatasi masalah *cold-start* pada pengguna baru, sistem yang diusulkan menerapkan strategi penanganan bertingkat (*multi-tier fallback strategy*) yang dirancang sesuai konteks ketersediaan data setiap pengguna. Pendekatan ini sejalan dengan rekomendasi pada literatur sistem rekomendasi hibrida modern [3], yang menyatakan bahwa *fallback* bertingkat merupakan teknik efektif untuk menjaga ketersediaan rekomendasi pada kondisi data minim. Tiga tingkatan strategi yang diterapkan adalah sebagai berikut:

1. *Cold-Start* Pengguna Anonim

Apabila pengguna mengakses sistem tanpa autentikasi, profil minat berbentuk vektor preferensi belum tersedia. Sistem secara otomatis melayani *feed* melalui algoritma trending global, yaitu pengurutan konten berdasarkan kombinasi metrik popularitas tanpa melibatkan komponen *Cosine Similarity*. Strategi ini memastikan pengguna baru tetap memperoleh konten populer yang relevan secara umum [9].

2. *Cold-Start* Pengguna Anonim

Untuk pengguna yang telah mendaftar tetapi belum memiliki rekam jejak interaksi, vektor preferensi U bernilai nol, sehingga *Cosine Similarity* (Persamaan 3.1) menghasilkan nilai nol. Sistem mendeteksi kondisi ini dan secara otomatis mengaktifkan jalur *fallback* ke kandidat trending yang telah dipra-komputasi pada cache.

3. *Cold-Start* dengan Preferensi Eksplisit dari *Onboarding*

Sistem menangkap preferensi eksplisit saat *onboarding* (registrasi awal). Preferensi ini disimpan dan ditambahkan sebagai skor dasar (*base score*) ke vektor preferensi pengguna U untuk memberikan dorongan awal pada perhitungan *Cosine Similarity*, sehingga personalisasi dapat aktif segera setelah registrasi. Pendekatan ini terbukti efektif mempersingkat masa *cold-start* [3].

3.2.2 *Arsitektur Sistem Rekomendasi Dua Tahap (Two-Stage Recommender System)*

Dalam implementasi sistem rekomendasi berskala besar, mengevaluasi dan menghitung skor kecocokan (seperti algoritma *Cosine Similarity* dan *Time Decay*) pada seluruh populasi data konten untuk setiap permintaan pengguna akan memakan biaya komputasi yang sangat besar dan mengakibatkan latensi yang tidak dapat diterima [12]. Untuk mengatasi tantangan skalabilitas tersebut, arsitektur sistem rekomendasi modern umumnya memecah proses pemfilteran ke dalam desain pipa data (*pipeline*) dua tahap:

Pembangkitan Kandidat (*Candidate Generation*) dan Perankingan (*Ranking/Scoring*) [12], [11].

1. Tahap Pembangkitan Kandidat (*Candidate Generation*)

Fase pertama ini berfungsi sebagai corong penyaring awal (*funnel*) yang bertujuan untuk mereduksi ruang lingkup pencarian secara masif. Sistem menyeleksi jutaan entri dalam basis data menjadi himpunan kandidat berukuran kecil (ratusan item) secara cepat dan komputasional murah [11]. Dalam konteks arsitektur hibrida, pengumpulan kandidat sering kali dilakukan dengan mengambil item dari berbagai *pool* atau strategi pencarian yang berjalan secara paralel untuk mencegah isolasi preferensi pengguna atau *filter bubble* [3]. Pada sistem yang diusulkan, kandidat diekstraksi dari tiga himpunan utama:

- a). Kandidat berdasarkan metrik interaksi global tertinggi (*Trending-based*).
- b). Kandidat berdasarkan ketertarikan kategori historis pengguna (*Interest-based*).
- c). Kandidat berdasarkan unggahan paling mutakhir (*Freshness-based*).

Seluruh kandidat dari berbagai sumber ini kemudian digabungkan (*merged*) dan dieliminasi duplikasinya sebelum masuk ke fase berikutnya [3].

2. Tahap Perankingan (*Ranking/Scoring*)

Fase kedua berfokus pada presisi dan penilaian mendalam terhadap himpunan kandidat terbatas yang telah lolos dari fase pertama [12]. Karena jumlah data yang diproses sudah jauh lebih kecil, sistem dapat menerapkan kalkulasi matematis komposit yang lebih berat untuk menentukan skor relevansi absolut dari setiap konten. Pada tahap inilah pilar algoritma hibrida utama dioperasikan secara bersamaan [13].

Setiap kandidat dinilai berdasarkan tingkat kemiripan vektor kategorinya (*Content Similarity*), kualitas interaksi historisnya (*Engagement Metrics*), serta

penalti peluruhan waktu (*Time-Awareness*). Konten yang memiliki skor gabungan hibrida tertinggi akan diurutkan secara menurun (*descending*) untuk dipresentasikan sebagai daftar rekomendasi akhir atau *For You Page* (FYP) kepada pengguna [11], [13]. Pendekatan penilaian dan perankingan berbasis multi-atribut ini sejalan dengan penelitian Andika, Kusnadi, dan Sokibi (2020), yang membuktikan bahwa metode komputasi pembobotan multi-kriteria sangat efektif untuk menghasilkan keputusan rekomendasi yang objektif dan presisi [22].

3.2.3 *Cosine Similarity*

Cosine Similarity adalah salah satu metrik pengukuran jarak (*distance metric*) yang paling masif dieksploitasi dalam sistem pemfilteran berbasis konten untuk mengevaluasi derajat kesamaan antara dua profil atau entitas [11]. Metrik ini tidak berfokus pada pengukuran selisih besaran ukuran (*magnitude*) antara dua profil, melainkan mengukur nilai kosinus sudut yang terbentuk di antara dua vektor tak nol di dalam sebuah ruang multidimensi (*multidimensional vector space*) [14].

Dalam konteks arsitektur sistem rekomendasi yang dikembangkan pada penelitian ini, algoritma *Cosine Similarity* secara spesifik diimplementasikan untuk mengkalkulasi tingkat relevansi antara vektor preferensi kategori milik pengguna (U) terhadap vektor atribut kategori yang merepresentasikan sebuah objek konten (C) [11]. Secara matematis, formulasi dari *Cosine Similarity* didefinisikan melalui persamaan berikut [14]:

$$sim(U, C) = \cos(\theta) = \frac{U \cdot C}{||U|| \cdot ||C||} = \frac{\sum_{i=1}^n U_i \cdot C_i}{\sqrt{\sum_{i=1}^n U_i^2} \cdot \sqrt{\sum_{i=1}^n C_i^2}} \quad (\text{Persamaan 3.2.3})$$

Keterangan persamaan di atas adalah sebagai berikut:

1. U_i merepresentasikan nilai bobot ketertarikan pengguna terhadap kategori ke- i (didapatkan dari riwayat interaksi pengguna).
2. C_i merepresentasikan keberadaan (*boolean*) atau bobot kategori ke- i yang melekat pada objek konten kandidat.
3. n mewakili total dimensi dari ruang vektor, yang ekuivalen dengan jumlah keseluruhan variasi kategori yang terdaftar di dalam sistem basis data.

Hasil dari perhitungan ruang vektor ini selalu menghasilkan metrik berskala dengan rentang nilai antara 0 hingga 1. Jika skor yang diproduksi mendekati nilai 1, kondisi tersebut mengindikasikan bahwa sudut antar vektor sangatlah sempit ($\theta \approx 0^\circ$), yang secara semantik berarti konten kandidat memiliki tingkat kemiripan atau kecocokan selera yang sangat identik dengan riwayat pengguna [4]. Sebaliknya, apabila skor yang dihasilkan mendekati atau sama dengan 0, kedua vektor diasumsikan saling tegak lurus (*orthogonal*), yang menegaskan ketiadaan irisan korelasi antara profil minat pengguna dengan kategori konten yang tengah dievaluasi [14]. Dalam kalkulasi perankingan hibrida yang diusulkan, metrik *Cosine Similarity* ini diposisikan sebagai pilar *Interest-Based* utama pembentuk skor akhir konten.

3.2.4 Time-Aware Ranking dan Exponential Time Decay

Sistem rekomendasi tradisional umumnya berasumsi bahwa preferensi pengguna dan relevansi sebuah item bersifat statis dari waktu ke waktu. Namun, pada platform penyedia konten yang dinamis, asumsi ini tidak lagi relevan [15]. Preferensi pengguna dapat bergeser, dan kebaruan (*novelty*) dari sebuah konten memiliki masa kedaluwarsa. Oleh karena itu, diperkenalkanlah paradigma *Time-Aware Recommender System* (TARS), yaitu sistem yang secara eksplisit

memodelkan waktu sebagai dimensi kontekstual tambahan dalam proses perankingan [15].

Salah satu teknik paling efektif dan komputasional ringan untuk mengimplementasikan TARS adalah melalui penggunaan fungsi peluruhan waktu atau *Time Decay Function* [16]. Secara khusus, *Exponential Time Decay* memberikan penalti secara mulus pada skor relevansi sebuah item berdasarkan usianya [16]. Pendekatan ini memastikan bahwa *item* yang baru dipublikasikan memiliki keunggulan visibilitas sementara, yang secara perlahan akan menyusut seiring berjalannya waktu, sehingga mencegah dominasi konten lama di halaman rekomendasi.

Sesuai dengan implementasi arsitektur sistem pada penelitian ini, skor kebaruan konten (*Freshness Score*) dihitung menggunakan persamaan peluruhan eksponensial berikut [16]:

$$S_{fresh}(C) = e^{-\frac{\Delta t}{\lambda}} \quad (\text{Persamaan 3.2.4})$$

Keterangan dari persamaan di atas adalah:

1. $S_{fresh}(C)$ adalah skor kebaruan akhir yang akan berkisar antara 0 hingga 1.
2. e adalah konstanta bilangan Euler (≈ 2.71828).
3. Δt adalah usia konten atau selisih antara waktu saat ini dengan waktu konten dibuat, yang direpresentasikan dalam satuan jam (*hours*).
4. λ adalah konstanta waktu paruh (*half-life parameter*) yang mengontrol seberapa curam kurva peluruhan terjadi. Pada penelitian ini, nilai λ ditetapkan sebesar 72.0 (mewakili 72 jam atau 3 hari), yang berarti konten akan kehilangan sebagian besar bobot kebaruannya secara signifikan setelah melewati siklus 3 hari.

Melalui integrasi fungsi peluruhan ini, sistem *hybrid* tidak hanya melayani kecocokan minat (*interest-based*), tetapi juga secara proaktif mendistribusikan eksposur (*exposure*) yang adil bagi konten-konten yang baru diunggah [15], [16].

3.2.5 *Engagement Metrics dan Normalisasi Data*

Kualitas intrinsik dari sebuah konten harus dievaluasi untuk memastikan bahwa sistem merekomendasikan item yang berharga. Evaluasi ini dilakukan dengan mengekstraksi *Engagement Metrics* (metrik keterlibatan), yaitu kumpulan sinyal interaksi historis pengguna terhadap konten tersebut [11]. Sinyal interaksi ini dapat berupa umpan balik eksplisit (*explicit feedback*) seperti rata-rata penilaian, maupun umpan balik implisit (*implicit feedback*) seperti jumlah klik, jumlah tayangan, penggunaan templat, dan jumlah suka [11].

Dalam membangun formula sistem hibrida, penggabungan langsung nilai *Engagement Metrics* (yang batas atasnya tidak terhingga) dengan skor probabilitas seperti seperti *Cosine Similarity* (yang bernilai 0 hingga 1) akan menyebabkan ketidakseimbangan model (*model bias*) [14]. Variabel dengan rentang nilai absolut yang jauh lebih besar akan mendominasi dan mengabaikan variabel lainnya [14].

Untuk menanggulangi ketimpangan ini, diperlukan teknik pra-pemrosesan data berupa Normalisasi (*Data Normalization*). Pada penelitian ini, teknik normalisasi penskalaan maksimum absolut (*Max-Absolute Scaling* atau turunan dari *Min-Max Normalization*) diterapkan untuk memampatkan nilai interaksi mentah ke dalam skala rasio homogen antara 0 hingga 1 [14]. Persamaan normalisasi tersebut didefinisikan sebagai:

$$X_{norm} = \frac{X}{X_{max}} \quad (\text{Persamaan 3.2.5})$$

Di mana X adalah nilai interaksi konten saat ini (misalnya jumlah suka dari sebuah postingan), dan X_{max} adalah nilai interaksi tertinggi dari seluruh himpunan kandidat yang sedang diproses pada ruang pencarian yang sama [14]. Hasil dari normalisasi metrik ini kemudian dikombinasikan (menjadi parameter *Quality Score*) bersama skor kemiripan dan skor kebaruan untuk menghasilkan nilai *ranking* hibrida yang terkalibrasi secara seimbang.

3.2.6 Hybrid Final Score

Setelah ketiga pilar penilaian kemiripan minat (*Cosine Similarity*), kebaruan konten (*Exponential Time Decay*), dan kualitas interaksi (*Quality Score*) terkalkulasi pada rentang ternormalisasi $[0, 1]$, langkah terakhir pada fase Ranking adalah menggabungkan ketiga skor tersebut menjadi satu metrik komposit tunggal yang menjadi dasar pengurutan akhir konten. Penggabungan ini menggunakan paradigma weighted linear combination sebagaimana dikategorikan dalam taksonomi sistem rekomendasi hibrida sebagai weighted hybrid recommender. Output dari beberapa teknik dihitung bersamaan dan dijumlahkan dengan bobot yang telah ditentukan.

Persamaan formal skor hibrida final pada penelitian ini didefinisikan sebagai berikut:

$$Score_{final}(c) = \omega_1 \cdot Cosine(u, c) + \omega_2 \cdot S_{fresh}(c) + \omega_3 \cdot Quality(c)$$

Keterangan persamaan:

1. $Score_{final}(c)$ adalah skor akhir konten kandidat c untuk pengguna u , pada rentang $[0, 1]$.
2. $Cosine(u, c)$ adalah skor kemiripan minat.
3. $S_{fresh}(c)$ adalah skor kebaruan konten (c).
4. $Quality(c)$ adalah skor kualitas konten (c).

5. ω_1, ω_2 , dan ω_3 adalah konstanta pembobotan.

Konstanta pembobotan tunduk pada kendala normalisasi:

$$\omega_1 + \omega_2 + \omega_3 = 1, \omega_i \in [0,1] \quad \forall_i \in \{1, 2, 3\}$$

Pada penelitian ini, ditetapkan nilai konstanta pembobotan sebagai berikut:

$$\omega_1 = 0,55, \omega_2 = 0,25 \quad \omega_3 = 0,20$$

Pemilihan kombinasi nilai ini didasarkan pada pertimbangan berikut:

1. Dominansi Pilar Minat (Cosine Similarity): Bobot tertinggi 0,55 dialokasikan untuk memastikan bahwa konten selaras dengan riwayat ketertarikan kategoris pengguna.
2. Kontribusi Moderat Pilar Kebaruan (Freshness): Bobot 0,25 memberikan visibilitas adil bagi konten baru tanpa mengorbankan relevansi minat, mencegah dominasi konten lama.
3. Kontribusi Penyaring Kualitas (Quality Score): Bobot 0,20 diposisikan sebagai filter terhadap konten berkualitas rendah, berfungsi sebagai pembanding antar konten dengan relevansi serupa.

Sifat matematis dari skor akhir ini bersifat monotonically non-decreasing dan memiliki kompleksitas komputasi rendah $O(n)$, memungkinkan respons real-time yang deterministik dan mudah di-tuning. Pada tahap akhir, sistem menerapkan pengurutan komposit sebagai berikut:

$$ORDER BY Score_{final}(c) DESC \rightarrow t_c DESC \rightarrow ID_{(c)} DESC$$